


ĐẠI HỌC BÁCH KHOA HÀ NỘI
KHOA TOÁN - TIN



BÁO CÁO CUỐI KỲ
HỌC PHẦN: CHUỖI THỜI GIAN

Chủ đề:

**Phân tích mô hình TimeMixer cho bài toán dự báo chuỗi
thời gian đa biến trên dữ liệu Electricity**

Giảng viên hướng dẫn: TS. Nguyễn Thị Ngọc Anh

Mã lớp: 169319

Nhóm sinh viên thực hiện: Đào Trung Hiếu - 20227048

Nguyễn Văn Hiệp - 20227016

Nguyễn Minh Huy - 20227020

Học kì: 2025.2

Hà Nội, 2026

Lời cảm ơn

Lời đầu tiên, nhóm chúng em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến Trường Đại học Bách Khoa Hà Nội, cùng Khoa Toán - Tin đã tạo ra một môi trường học tập, nghiên cứu khoa học chuyên nghiệp và cung cấp cho chúng em những nền tảng kiến thức vô cùng quý báu.

Đặc biệt, nhóm chúng em xin bày tỏ lòng biết ơn sâu sắc đến **TS. Nguyễn Thị Ngọc Anh**, giảng viên trực tiếp giảng dạy học phần **Chuỗi thời gian**. Trong suốt học kỳ qua, Cô không chỉ truyền đạt những kiến thức chuyên môn sâu rộng mà còn tận tình hướng dẫn, định hướng nghiên cứu và giải đáp mọi thắc mắc, giúp chúng em có thể hoàn thành tốt bài báo cáo môn học này. Sự tâm huyết và những định hướng khoa học sắc bén của Cô chính là nguồn động lực lớn để chúng em nỗ lực tìm tòi, triển khai thực nghiệm và vượt qua các rào cản kỹ thuật trong quá trình thực hiện đề tài.

Bên cạnh đó, chúng em cũng xin dành sự trân trọng cho tinh thần làm việc tập thể của các thành viên trong nhóm. Sự phối hợp ăn ý, cùng nhau thảo luận và chia sẻ khối lượng công việc đã giúp nhóm hoàn thành báo cáo đúng tiến độ.

Mặc dù đã có nhiều cố gắng trong việc tổng hợp kiến thức và triển khai mã nguồn, nhưng do giới hạn về mặt thời gian cũng như kinh nghiệm thực tiễn, bài báo cáo chắc chắn không thể tránh khỏi những thiếu sót. Chúng em rất mong nhận được sự lượng thứ cũng như những lời nhận xét, góp ý quý báu từ Cô để bài làm được hoàn thiện hơn, đồng thời giúp chúng em rút ra những bài học kinh nghiệm sâu sắc cho các định hướng học tập và nghiên cứu sau này.

Một lần nữa, chúng em xin chân thành cảm ơn!

Hà Nội, tháng 06 năm 2026

Nhóm sinh viên thực hiện

Đào Trung Hiếu

Nguyễn Văn Hiệp

Nguyễn Minh Huy

Lời mở đầu

Trong kỷ nguyên chuyển đổi số và dữ liệu lớn hiện nay, dữ liệu chuỗi thời gian (Time Series) đóng vai trò huyết mạch trong việc vận hành và ra quyết định của vô số các hệ thống thực tế: từ quản lý lưới điện thông minh, dự báo khí hậu, đến tối ưu hóa chuỗi cung ứng và giao dịch tài chính. Tuy nhiên, dữ liệu chuỗi thời gian trong thực tiễn hiếm khi tồn tại ở trạng thái tĩnh. Chúng thường là sự đan xen phức tạp của nhiều thành phần biến động ở các tần số khác nhau, như xu hướng dài hạn (vĩ mô) và tính mùa vụ ngắn hạn (vi mô). Việc các mô hình học sâu hiện đại cố gắng ánh xạ tất cả các đặc trưng này vào cùng một không gian biểu diễn đã vô tình dẫn đến hiện tượng "xáo trộn quy mô" (Scale Mixing), làm giảm đáng kể hiệu năng dự báo ở các tầm nhìn xa.

Nhận thức được thách thức này, đồng thời vận dụng những kiến thức nền tảng quý báu đã tiếp thu từ học phần Chuỗi thời gian, nhóm chúng em quyết định lựa chọn hướng nghiên cứu chuyên sâu về kiến trúc mạng học sâu đa quy mô. Cụ thể, báo cáo tập trung mổ xẻ và phân tích mô hình đột phá được giới thiệu trong bài báo: "TimeMixer: Decomposable Multiscale Mixing for Time Series Forecasting" của nhóm tác giả Shiyu Wang et al. (2024).

Báo cáo này không chỉ dừng lại ở việc hệ thống hóa lý thuyết về cơ chế phân tách Trend - Seasonality (Decomposable Mixing) của TimeMixer, mà còn tập trung triển khai thực nghiệm đối sánh toàn diện. Bằng việc đặt TimeMixer lên bàn cân với các phương pháp đại diện cho các kỷ nguyên khác nhau như Seasonal Naive (Thuần thống kê) và XGBoost (Học máy truyền thống) trên tập dữ liệu thực tế Electricity, nhóm mong muốn làm nổi bật giới hạn của các phương pháp cũ cũng như sức mạnh ưu việt của mạng thuần MLP trong việc nắm bắt động học chuỗi thời gian.

Mục lục

Lời mở đầu		ii
I	GIỚI THIỆU	1
1	Bối cảnh nghiên cứu	1
2	Đặc trưng phức tạp của chuỗi thời gian thực tế	1
3	Hạn chế của một số hướng tiếp cận truyền thống	2
4	Động lực lựa chọn TimeMixer	3
5	Mục tiêu của báo cáo	3
6	Phạm vi nghiên cứu	4
7	Dóng góp của báo cáo	4
8	Cấu trúc báo cáo	5
II	CƠ SỞ LÝ THUYẾT VÀ CÁC MÔ HÌNH NỀN TẢNG	5
1	Phát biểu bài toán dự báo chuỗi thời gian đa biến	5
2	Cửa sổ trượt và tạo tập dữ liệu có giám sát	6
3	Phân rã chuỗi thời gian	6
4	Mô hình Seasonal Naive	7
5	Mô hình XGBoost cho dự báo chuỗi thời gian	8
6	Kiến trúc MLP và tư tưởng Mixing	9
7	Phân tích đa quy mô	10
8	Vai trò của ba mô hình trong báo cáo	10
III	KIẾN TRÚC MÔ HÌNH TIMEMIXER	10
1	Tổng quan kiến trúc	10
2	Ký hiệu đầu vào và đầu ra	12
3	Tạo chuỗi đa quy mô bằng average pooling	12
4	Khối Past-Decomposable-Mixing	13
5	Seasonal Mixing theo hướng bottom-up	14
6	Trend Mixing theo hướng top-down	15
7	Tổng hợp trong một khối PDM	15

8	Khối Future-Multipredictor-Mixing	16
9	Thuật toán tổng quát của TimeMixer	16
10	Hàm mất mát	17
11	Phân tích độ phức tạp	17
12	Bằng chứng từ nghiên cứu ablation trong paper	18
13	Ý nghĩa học thuật của TimeMixer	18
IV	THIẾT LẬP VÀ KẾT QUẢ THỰC NGHIỆM	19
1	Mô tả tập dữ liệu Electricity	19
2	Tiền xử lý dữ liệu và tạo mẫu	20
3	Thiết lập thực nghiệm	24
4	Chỉ số đánh giá	26
5	Kết quả định lượng tổng quan	26
6	Phân tích xu hướng sai số theo horizon	27
7	Mức cải thiện tương đối của TimeMixer	27
8	Phân tích riêng từng mô hình	28
9	Liên hệ với kết quả trong bài báo gốc	29
10	Kết luận chương	29
V	PHÂN TÍCH KHẢ NĂNG DIỄN GIẢI VÀ TRỰC QUAN HÓA DỮ LIỆU	30
1	Vai trò của trực quan hóa trong đánh giá mô hình	30
2	Các tiêu chí phân tích định tính	30
3	TimeMixer trên toàn bộ tập kiểm tra	31
4	Seasonal Naive trên toàn bộ tập kiểm tra	32
5	XGBoost trên toàn bộ tập kiểm tra	33
6	So sánh định tính ba mô hình	33
7	Phân tích miền tần số	34
8	Diễn giải vai trò của PDM từ hình dự báo	35
9	Kết luận chương	36
VI	THẢO LUẬN VÀ ĐÁNH GIÁ CHUYÊN SÂU	36

1	Tại sao Seasonal Naive có thể vượt XGBoost?	36
2	Giới hạn của XGBoost trong dự báo chuỗi dài	37
3	Ưu thế của TimeMixer trong dữ liệu đa quy mô	37
4	Mối quan hệ giữa TimeMixer và các mô hình Transformer	38
5	Ý nghĩa thực tiễn trong dự báo phụ tải điện	39
6	Các dạng sai số còn tồn tại	39
7	Hạn chế của báo cáo	39
8	Bài học phương pháp luận	40
VII	ĐỀ XUẤT CẢI TIẾN PHƯƠNG PHÁP	40
1	Mục tiêu cải tiến	40
2	Tích hợp biến ngoại sinh	40
3	Cải tiến hàm mất mát	42
4	Bổ sung nhánh phát hiện spike	43
5	Tối ưu số quy mô và độ dài lookback	43
6	Đánh giá theo từng nhóm kênh	44
7	Kế hoạch kiểm chứng các cải tiến	44
8	Kết luận chương	45
VIII	KẾT LUẬN	45
1	Tổng kết nội dung nghiên cứu	45
2	Kết luận về mặt lý thuyết	45
3	Kết luận về mặt thực nghiệm	46
4	Ý nghĩa ứng dụng	46
5	Hướng phát triển tiếp theo	47
6	Lời kết	47

Danh sách hình vẽ

1	Kiến trúc tổng thể TimeMixer gồm ba phần: tạo chuỗi đa quy mô, trộn quá khứ bằng PDM và tổng hợp dự báo tương lai bằng FMM.	11
2	Minh họa phân rã chuỗi thành thành phần xu hướng và mùa vụ. TimeMixer thực hiện ý tưởng này ở từng quy mô trước khi trộn thông tin.	14
3	Mẫu hình tiêu thụ điện minh họa tính chu kỳ ngày–đêm trong dữ liệu Electricity.	19
4	Xu hướng MSE theo tầm dự báo trên dữ liệu Electricity.	27
5	Mức giảm MSE của TimeMixer so với Seasonal Naive và XGBoost.	28
6	Dự báo TimeMixer trên toàn bộ tập kiểm tra với $lookback = 96$ và $pred_len = 96$	31
7	Dự báo Seasonal Naive trên toàn bộ tập kiểm tra với $lookback = 96$ và $pred_len = 96$	32
8	Dự báo XGBoost trên toàn bộ tập kiểm tra với $lookback = 96$ và $pred_len = 96$	33
9	Minh họa phân tích phổ tần số FFT để quan sát các thành phần chu kỳ trong chuỗi.	35

I GIỚI THIỆU

1 Bối cảnh nghiên cứu

Dự báo chuỗi thời gian đa biến (multivariate time series forecasting) là một bài toán nền tảng trong khoa học dữ liệu hiện đại. Trong nhiều hệ thống thực tế như lưới điện, giao thông, khí tượng, tài chính, bán lẻ và vận hành công nghiệp, dữ liệu không xuất hiện dưới dạng các mẫu độc lập mà được sinh ra liên tục theo thời gian. Mỗi quan sát tại thời điểm t không chỉ mang thông tin riêng của thời điểm đó, mà còn chịu ảnh hưởng của các quan sát trước đó, của chu kỳ lặp lại, của xu hướng dài hạn và của nhiễu ngẫu nhiên. Vì vậy, dự báo chuỗi thời gian khác với hồi quy bảng thông thường ở chỗ mô hình phải đồng thời học được quan hệ theo thời gian, quan hệ giữa các biến và quy luật biến đổi ở nhiều thang thời gian khác nhau.

Trong dữ liệu phụ tải điện, tính chất đa biến thể hiện ở việc nhiều khách hàng hoặc nhiều khu vực tiêu thụ điện được ghi nhận đồng thời. Các chuỗi này có thể cùng chịu ảnh hưởng của nhịp sinh hoạt chung, nhưng cũng có mức nền và biên độ dao động riêng. Một khách hàng dân cư có thể có đỉnh tiêu thụ vào buổi tối, trong khi một đơn vị sản xuất có thể có đỉnh vào giờ làm việc. Do đó, mô hình dự báo tốt cần vừa nắm bắt mẫu hình chung, vừa giữ được đặc trưng riêng của từng kênh. Đây là lý do dữ liệu Electricity thường được sử dụng như một benchmark quan trọng trong các nghiên cứu dự báo dài hạn.

2 Đặc trưng phức tạp của chuỗi thời gian thực tế

Một chuỗi thời gian thực tế hiếm khi chỉ chứa một thành phần duy nhất. Về mặt phân tích, ta có thể hình dung chuỗi được tạo bởi sự kết hợp của các thành phần sau:

- **Xu hướng dài hạn (trend):** phản ánh sự thay đổi chậm của mức nền, ví dụ nhu cầu điện tăng dần theo mùa nóng hoặc giảm trong kỳ nghỉ dài.
- **Mùa vụ và chu kỳ (seasonality/cycle):** phản ánh các dao động lặp lại theo giờ, ngày, tuần hoặc tháng.
- **Dao động ngắn hạn:** phản ánh biến động cục bộ, thay đổi hành vi tức thời

hoặc nhiều cảm biến.

- **Sự kiện bất thường:** phản ánh spike, đứt gãy cấu trúc, ngày lễ hoặc thay đổi vận hành đột ngột.

Các thành phần này không tách rời một cách rõ ràng trong dữ liệu quan sát. Chúng bị trộn lẫn trong cùng một chuỗi đầu vào. Khi mô hình xử lý chuỗi ở một độ phân giải duy nhất, dao động ngắn hạn có thể làm nhiễu xu hướng dài hạn; ngược lại, xu hướng dài hạn có thể làm mờ những dao động mùa vụ quan trọng. Vì vậy, bài toán dự báo không chỉ là tìm một hàm ánh xạ từ quá khứ sang tương lai, mà còn là bài toán tổ chức lại thông tin quá khứ sao cho các thành phần có bản chất khác nhau được mô hình hóa đúng cách.

3 Hạn chế của một số hướng tiếp cận truyền thống

Các mô hình thống kê cổ điển như Naive, Seasonal Naive, ARIMA hoặc các biến thể phân rã mùa vụ có ưu điểm là dễ hiểu và bám sát tri thức chuỗi thời gian. Tuy nhiên, chúng thường gặp khó khi mở rộng sang dữ liệu đa biến quy mô lớn hoặc khi quan hệ giữa các biến thay đổi theo thời gian. Mặt khác, các mô hình học máy truyền thống như Random Forest, XGBoost hoặc SVR có khả năng học phi tuyến mạnh nhưng lại không được thiết kế tự nhiên cho dữ liệu tuần tự. Để dùng các mô hình này, người nghiên cứu phải biến đổi chuỗi thành bài toán có giám sát thông qua các đặc trưng trễ, đặc trưng thời gian và thống kê trượt. Chất lượng dự báo vì vậy phụ thuộc nhiều vào kỹ nghệ đặc trưng.

Trong thập kỷ gần đây, các mô hình học sâu như RNN, CNN, Transformer và MLP đã được áp dụng rộng rãi cho dự báo chuỗi thời gian. RNN có khả năng mô hình hóa trạng thái tuần tự nhưng khó huấn luyện với chuỗi dài; CNN có ưu thế trích xuất mẫu cục bộ nhưng trường nhìn bị giới hạn nếu không tăng số lớp hoặc dùng dilation; Transformer có khả năng mô hình hóa phụ thuộc dài hạn thông qua attention nhưng chi phí tính toán và bộ nhớ thường tăng nhanh theo độ dài chuỗi. Các mô hình thuần MLP gần đây cho thấy hiệu quả đáng chú ý, song MLP thông thường vẫn có thể nhầm lẫn giữa xu hướng và mùa vụ nếu tất cả thành phần được trộn trong cùng một không gian biểu diễn.

4 Động lực lựa chọn TimeMixer

Bài báo *TimeMixer: Decomposable Multiscale Mixing for Time Series Forecasting* [1] đề xuất nhìn bài toán dự báo dưới góc độ **trộn đa quy mô** (multiscale mixing). Trực giác chính của TimeMixer là cùng một chuỗi thời gian sẽ bộc lộ các mẫu hình khác nhau khi được quan sát ở các thang lấy mẫu khác nhau. Ở quy mô mịn, mô hình nhìn thấy các dao động chi tiết và mùa vụ ngắn hạn. Ở quy mô thô, các nhiễu cục bộ được làm trơn, nhờ đó xu hướng dài hạn trở nên rõ hơn.

Điểm mới của TimeMixer không chỉ là tạo ra nhiều chuỗi hạ lấy mẫu, mà còn là cách trộn thông tin giữa các quy mô. Mô hình sử dụng khối **Past-Decomposable-Mixing (PDM)** để phân rã từng quy mô thành thành phần mùa vụ và xu hướng, sau đó trộn hai thành phần theo hai hướng khác nhau: mùa vụ được trộn từ quy mô mịn lên quy mô thô, còn xu hướng được trộn từ quy mô thô xuống quy mô mịn. Sau giai đoạn trích xuất quá khứ, mô hình sử dụng **Future-Multipredictor-Mixing (FMM)** để tổng hợp nhiều bộ dự báo từ các quy mô khác nhau. Cách thiết kế này giúp TimeMixer kết hợp được cả thông tin vi mô và vĩ mô trong cùng một kiến trúc thuần MLP.

5 Mục tiêu của báo cáo

Báo cáo này được xây dựng với mục tiêu trình bày lại một cách chi tiết, có hệ thống và theo văn phong học thuật nội dung chính của TimeMixer, đồng thời triển khai phân tích thực nghiệm trên dữ liệu Electricity. Cụ thể, báo cáo hướng đến các mục tiêu sau:

- Làm rõ bài toán dự báo chuỗi thời gian đa biến, các ký hiệu toán học, cách tạo mẫu dự báo bằng cửa sổ trượt và các chỉ số đánh giá.
- Trình bày chi tiết cơ sở lý thuyết của ba hướng tiếp cận được sử dụng trong báo cáo: Seasonal Naive, XGBoost và TimeMixer.
- Phân tích sâu kiến trúc TimeMixer, bao gồm hạ lấy mẫu đa quy mô, phân rã mùa vụ-xu hướng, Seasonal Mixing, Trend Mixing và Future-Multipredictor-Mixing.
- Đối sánh kết quả định lượng giữa TimeMixer, Seasonal Naive và XGBoost trên

dữ liệu Electricity với cửa sổ quan sát $L = 96$.

- Bổ sung phần trực quan hóa toàn bộ tập kiểm tra dựa trên các hình ảnh dự báo đã sinh ra, từ đó đánh giá định tính khả năng bám xu hướng, tái tạo chu kỳ và xử lý spike của từng mô hình.

6 Phạm vi nghiên cứu

Phạm vi thực nghiệm của báo cáo tập trung vào tập dữ liệu Electricity. Cửa sổ quan sát chính được cố định ở $L = 96$, tương ứng với 96 giờ lịch sử. Với dữ liệu lấy mẫu theo giờ, độ dài này bao phủ bốn chu kỳ ngày–đêm liên tiếp, đủ để cung cấp tín hiệu mùa vụ ngắn hạn nhưng vẫn tạo ra bài toán khó khi tầm dự báo kéo dài. Các tầm dự báo được xét trong phần định lượng gồm $H \in \{96, 192, 336, 720\}$. Riêng phần trực quan hóa toàn bộ tập kiểm tra sử dụng các hình với cấu hình $lookback = 96$ và $pred_len = 96$.

Ba mô hình được chọn có vai trò bổ sung cho nhau. Seasonal Naive đại diện cho đường cơ sở thống kê dựa trên giả định mùa vụ. XGBoost đại diện cho học máy truyền thống dựa trên cây tăng cường gradient. TimeMixer đại diện cho học sâu đa quy mô theo hướng thuần MLP. Việc đặt ba mô hình này cạnh nhau giúp kết quả phân tích không chỉ trả lời câu hỏi mô hình nào có sai số thấp hơn, mà còn làm rõ tại sao một mô hình phù hợp hoặc không phù hợp với dữ liệu điện năng.

7 Đóng góp của báo cáo

So với việc chỉ tóm tắt paper, báo cáo này có bốn đóng góp cụ thể. Thứ nhất, nội dung của TimeMixer được diễn giải lại bằng tiếng Việt theo hướng phù hợp với môn học Chuỗi thời gian, trong đó các ký hiệu và phương trình được trình bày tuần tự. Thứ hai, báo cáo mở rộng phần so sánh bằng cách đưa Seasonal Naive và XGBoost vào cùng một khung phân tích. Thứ ba, báo cáo bổ sung trực quan hóa dự báo trên toàn bộ tập kiểm tra, giúp nhận diện dạng sai số mà các chỉ số MSE/MAE/RMSE không thể hiện đầy đủ. Thứ tư, báo cáo đề xuất một số cải tiến thực tế như tích hợp biến ngoại sinh, thay đổi hàm mất mát và thêm cơ chế phát hiện spike.

8 Cấu trúc báo cáo

Báo cáo gồm tám chương. Chương 1 giới thiệu bối cảnh, vấn đề nghiên cứu, mục tiêu và phạm vi. Chương 2 trình bày cơ sở lý thuyết và các mô hình nền tảng. Chương 3 phân tích chi tiết kiến trúc TimeMixer. Chương 4 mô tả dữ liệu, thiết lập thực nghiệm và kết quả định lượng. Chương 5 trình bày trực quan hóa dự báo trên toàn bộ tập kiểm tra. Chương 6 thảo luận sâu về ý nghĩa kết quả, ưu điểm và hạn chế. Chương 7 đề xuất các hướng cải tiến. Chương 8 tổng kết nội dung và nêu triển vọng ứng dụng.

II CƠ SỞ LÝ THUYẾT VÀ CÁC MÔ HÌNH NỀN TẢNG

1 Phát biểu bài toán dự báo chuỗi thời gian đa biến

Xét chuỗi thời gian đa biến gồm C biến được quan sát trong T thời điểm:

$$\mathbf{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T\}, \quad \mathbf{x}_t \in \mathbb{R}^C. \quad (1)$$

Tại một thời điểm t , mô hình nhận đầu vào là cửa sổ quá khứ có độ dài L :

$$\mathbf{X}_{t-L+1:t} = [\mathbf{x}_{t-L+1}, \mathbf{x}_{t-L+2}, \dots, \mathbf{x}_t] \in \mathbb{R}^{L \times C}, \quad (2)$$

và cần dự báo H bước tương lai:

$$\hat{\mathbf{Y}}_{t+1:t+H} = [\hat{\mathbf{x}}_{t+1}, \hat{\mathbf{x}}_{t+2}, \dots, \hat{\mathbf{x}}_{t+H}] \in \mathbb{R}^{H \times C}. \quad (3)$$

Một mô hình dự báo có thể được viết dưới dạng ánh xạ:

$$f_{\Theta} : \mathbb{R}^{L \times C} \rightarrow \mathbb{R}^{H \times C}, \quad \hat{\mathbf{Y}} = f_{\Theta}(\mathbf{X}_{t-L+1:t}), \quad (4)$$

trong đó Θ là tập tham số cần học. Khi $H = 1$, bài toán là dự báo một bước. Khi $H > 1$, bài toán trở thành dự báo đa bước, khó hơn vì sai số có thể tăng theo horizon và vì mô hình phải tái tạo cấu trúc động của toàn bộ đoạn tương lai.

2 Cửa sổ trượt và tạo tập dữ liệu có giám sát

Để huấn luyện mô hình, chuỗi thời gian thường được biến đổi thành tập mẫu bằng cửa sổ trượt. Với mỗi vị trí t , ta tạo một cặp đầu vào–nhãn:

$$(\mathbf{X}_{t-L+1:t}, \mathbf{X}_{t+1:t+H}). \quad (5)$$

Nếu bước trượt bằng 1, số lượng mẫu thu được xấp xỉ $T - L - H + 1$. Cách tạo mẫu này giúp tận dụng tối đa dữ liệu, nhưng cũng làm các mẫu huấn luyện có độ chồng lấn cao. Trong chuỗi thời gian, việc chia tập huấn luyện, kiểm định và kiểm tra phải giữ nguyên trật tự thời gian; không thể xáo trộn ngẫu nhiên như dữ liệu độc lập, vì làm như vậy sẽ gây rò rỉ thông tin tương lai vào quá khứ.

3 Phân rã chuỗi thời gian

Một cách nhìn cổ điển trong phân tích chuỗi thời gian là xem chuỗi quan sát gồm ba thành phần:

$$y_t = T_t + S_t + R_t, \quad (6)$$

trong đó T_t là xu hướng, S_t là mùa vụ/chu kỳ và R_t là phần dư. Đối với dữ liệu phụ tải điện, thành phần mùa vụ thường rất mạnh vì hành vi tiêu thụ lặp lại theo ngày và theo tuần. Thành phần xu hướng thể hiện sự thay đổi mức nền chậm hơn, còn phần dư phản ánh nhiễu hoặc sự kiện bất thường.

Một phương pháp phổ biến để ước lượng xu hướng là trung bình trượt:

$$T_t = \frac{1}{K} \sum_{i=-r}^r y_{t+i}, \quad K = 2r + 1. \quad (7)$$

Sau đó, thành phần mùa vụ hoặc phần dao động còn lại có thể được tính bằng:

$$S_t + R_t = y_t - T_t. \quad (8)$$

TimeMixer kế thừa trực giác phân rã này, nhưng không chỉ áp dụng trên chuỗi gốc. Mô hình tạo ra nhiều chuỗi ở các quy mô khác nhau, sau đó phân rã từng quy mô để xử lý

mùa vụ và xu hướng bằng các luồng trộn riêng.

4 Mô hình Seasonal Naive

4.1 Định nghĩa toán học

Seasonal Naive là mô hình dự báo cơ sở mạnh cho chuỗi có tính mùa vụ rõ ràng. Giả sử chuỗi đơn biến $\{y_1, y_2, \dots, y_t\}$ có chu kỳ mùa vụ m . Dự báo tại bước h được lấy bằng giá trị quan sát ở cùng pha mùa vụ gần nhất trong quá khứ:

$$\hat{y}_{t+h|t} = y_{t+h-m(k+1)}, \quad k = \left\lfloor \frac{h-1}{m} \right\rfloor. \quad (9)$$

Công thức trên đảm bảo chỉ sử dụng các giá trị không vượt quá thời điểm t . Với dữ liệu theo giờ và chu kỳ ngày–đêm, ta thường chọn $m = 24$. Khi đó, phụ tải tại 9 giờ sáng ngày mai được dự báo bằng phụ tải tại 9 giờ sáng ngày hôm nay hoặc chu kỳ gần nhất tương ứng.

4.2 Ý nghĩa thống kê

Seasonal Naive không học tham số. Toàn bộ sức mạnh của mô hình nằm ở giả định rằng mẫu hình mùa vụ lặp lại tương đối ổn định. Vì không có tham số, mô hình gần như không có nguy cơ quá khớp theo nghĩa thông thường. Nó cũng rất dễ giải thích và là một baseline quan trọng: nếu một mô hình phức tạp không vượt được Seasonal Naive, điều đó cho thấy mô hình chưa học được cấu trúc mùa vụ cơ bản của dữ liệu.

Tuy nhiên, Seasonal Naive có các hạn chế rõ ràng. Mô hình không học được xu hướng dài hạn, không thích ứng tốt khi mức nền thay đổi, không khai thác tương quan giữa các biến và dễ sao chép nhiều từ quá khứ sang tương lai. Vì vậy, Seasonal Naive phù hợp để làm mốc tham chiếu, nhưng không đủ linh hoạt cho các hệ thống có nhiều yếu tố ngoại sinh hoặc đứt gãy cấu trúc.

5 Mô hình XGBoost cho dự báo chuỗi thời gian

5.1 Nguyên lý tăng cường gradient

XGBoost [2] là thuật toán học máy dựa trên tập hợp cây quyết định. Mô hình xây dựng các cây một cách tuần tự; mỗi cây mới được huấn luyện để giảm sai số còn lại của các cây trước đó. Dự báo sau q vòng lặp có dạng:

$$\hat{y}_i^{(q)} = \sum_{j=1}^q f_j(\mathbf{z}_i) = \hat{y}_i^{(q-1)} + f_q(\mathbf{z}_i), \quad (10)$$

trong đó $\mathbf{z}_i$ là vector đặc trưng đầu vào và f_q là cây quyết định thứ q .

Hàm mục tiêu tổng quát gồm sai số huấn luyện và thành phần chính quy hóa:

$$\mathcal{L}^{(q)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(q-1)} + f_q(\mathbf{z}_i)) + \Omega(f_q), \quad (11)$$

$$\Omega(f_q) = \gamma J + \frac{1}{2} \lambda \sum_{j=1}^J w_j^2, \quad (12)$$

trong đó J là số lá của cây, w_j là trọng số tại lá thứ j , γ phạt số lá và λ phạt độ lớn trọng số. Thành phần chính quy hóa giúp mô hình tránh tạo cây quá phức tạp.

Nếu khai triển Taylor bậc hai quanh $\hat{y}^{(q-1)}$, ta có xấp xỉ:

$$\mathcal{L}^{(q)} \approx \sum_{i=1}^n \left[g_i f_q(\mathbf{z}_i) + \frac{1}{2} h_i f_q^2(\mathbf{z}_i) \right] + \Omega(f_q), \quad (13)$$

trong đó g_i và h_i lần lượt là gradient bậc nhất và bậc hai của hàm mất mát theo dự báo hiện tại. Đây là cơ sở giúp XGBoost tìm cách chia cây tối ưu một cách hiệu quả.

5.2 Áp dụng XGBoost cho chuỗi thời gian

XGBoost không nhận biết trật tự thời gian một cách tự nhiên. Để áp dụng cho chuỗi thời gian, cần biến đổi chuỗi thành vector đặc trưng bằng các giá trị trễ:

$$\mathbf{z}_t = [y_t, y_{t-1}, \dots, y_{t-L+1}, \phi(t)], \quad (14)$$

trong đó $\phi(t)$ có thể chứa các đặc trưng thời gian như giờ trong ngày, ngày trong tuần, chỉ báo cuối tuần hoặc thống kê trượt. Nếu thiếu các đặc trưng thời gian này, XGBoost phải tự suy ra mùa vụ từ các giá trị trễ, điều này thường khó khi chu kỳ dài hoặc khi horizon lớn.

Với dự báo đa bước, có ba chiến lược chính:

- **Recursive:** huấn luyện một mô hình dự báo một bước, sau đó dùng dự báo làm đầu vào để dự báo bước tiếp theo. Cách này tiết kiệm nhưng dễ tích lũy sai số.
- **Direct:** huấn luyện một mô hình riêng cho từng horizon h . Cách này giảm lan truyền sai số nhưng tốn tài nguyên và không học quan hệ giữa các bước tương lai.
- **Multi-output:** huấn luyện mô hình dự báo trực tiếp toàn bộ vector tương lai. Cách này phù hợp hơn với dự báo đa bước nhưng không phải mọi mô hình cây đều hỗ trợ hiệu quả.

5.3 Giới hạn của XGBoost trong chuỗi dài

Mô hình cây quyết định có xu hướng tạo dự báo theo từng vùng của không gian đặc trưng. Do đó, đường dự báo thường ít mượt hơn các mô hình học biểu diễn tuần tự. Ngoài ra, cây quyết định không ngoại suy tốt ra ngoài phạm vi dữ liệu huấn luyện. Khi xu hướng tương lai vượt khỏi các mức đã quan sát, XGBoost thường trả về giá trị gần với các lá đã học, dẫn đến hiện tượng làm phẳng dự báo. Đây là một nguyên nhân khiến XGBoost có thể yếu hơn Seasonal Naive trong các chuỗi có mùa vụ mạnh.

6 Kiến trúc MLP và tư tưởng Mixing

MLP-Mixer [3] cho thấy rằng các lớp tuyến tính và phi tuyến đơn giản có thể trộn thông tin hiệu quả nếu dữ liệu được tổ chức đúng chiều. Trong chuỗi thời gian, ta có thể phân biệt hai loại trộn:

- **Temporal mixing:** trộn theo chiều thời gian, cho phép các điểm trong cửa sổ quá khứ tương tác với nhau.
- **Channel mixing:** trộn theo chiều biến, cho phép các kênh trong chuỗi đa biến trao đổi thông tin.

So với Transformer, MLP không cần tính ma trận attention toàn cục kích thước $L \times L$. Điều này giúp giảm chi phí tính toán khi L lớn. Tuy nhiên, MLP chỉ thực sự hiệu quả nếu kiến trúc có khả năng định tuyến đúng loại thông tin. TimeMixer chính là một ví dụ: mô hình không trộn tất cả tín hiệu một cách đồng nhất, mà trộn theo quy mô và theo bản chất mùa vụ-xu hướng.

7 Phân tích đa quy mô

Phân tích đa quy mô dựa trên ý tưởng rằng cùng một tín hiệu có thể mang ý nghĩa khác nhau ở các độ phân giải khác nhau. Khi hạ lấy mẫu, dao động nhanh bị giảm bớt, trong khi xu hướng chậm trở nên nổi bật. Nếu ký hiệu chuỗi gốc là $\mathbf{x}_0$, một phép hạ lấy mẫu trung bình đơn giản có thể viết:

$$\mathbf{x}_m[i, c] = \frac{1}{2} (\mathbf{x}_{m-1}[2i, c] + \mathbf{x}_{m-1}[2i + 1, c]), \quad (15)$$

trong đó m là chỉ số quy mô. Sau m lần hạ lấy mẫu, độ dài chuỗi xấp xỉ $\lfloor L/2^m \rfloor$. Quy mô mịn bảo toàn chi tiết; quy mô thô làm rõ xu hướng. TimeMixer tận dụng trực giác này để xây dựng biểu diễn quá khứ đa quy mô trước khi dự báo.

8 Vai trò của ba mô hình trong báo cáo

Ba mô hình trong báo cáo tạo thành ba mức độ mô hình hóa. Seasonal Naive là mô hình thống kê tối giản nhưng có tri thức mùa vụ rõ ràng. XGBoost là mô hình học máy phi tuyến mạnh nhưng phụ thuộc vào kỹ nghệ đặc trưng. TimeMixer là mô hình học sâu được thiết kế riêng cho chuỗi thời gian đa quy mô. Việc so sánh ba mô hình này giúp trả lời ba câu hỏi: mùa vụ đơn thuần mạnh đến đâu, học máy truyền thống xử lý chuỗi tốt đến đâu, và kiến trúc đa quy mô của TimeMixer đem lại lợi ích gì.

III KIẾN TRÚC MÔ HÌNH TIMEMIXER


1 Tổng quan kiến trúc

TimeMixer [1] là một mô hình dự báo chuỗi thời gian dựa trên MLP, được thiết kế để xử lý biến động phức tạp bằng cách kết hợp phân tích đa quy mô và phân rã

mùa vụ–xu hướng. Khác với các mô hình xử lý chuỗi ở một độ phân giải duy nhất, TimeMixer tạo ra nhiều phiên bản của chuỗi quá khứ ở các mức hạ lấy mẫu khác nhau. Mỗi mức quy mô phản ánh một lát cắt khác nhau của tín hiệu: quy mô mịn nhấn mạnh dao động ngắn hạn, còn quy mô thô nhấn mạnh xu hướng dài hạn.

Kiến trúc tổng thể gồm ba giai đoạn:

1. **Multiscale Time Series:** tạo tập chuỗi đa quy mô từ chuỗi đầu vào bằng average pooling.
2. **Past-Decomposable-Mixing (PDM):** phân rã từng chuỗi đa quy mô thành thành phần mùa vụ và xu hướng, sau đó trộn hai thành phần theo hai hướng khác nhau.
3. **Future-Multipredictor-Mixing (FMM):** sử dụng nhiều bộ dự báo tương ứng với nhiều quy mô và tổng hợp chúng thành dự báo cuối cùng.



Hình 1: Kiến trúc tổng thể TimeMixer gồm ba phần: tạo chuỗi đa quy mô, trộn quá khứ bằng PDM và tổng hợp dự báo tương lai bằng FMM.

Hình 1 cho thấy TimeMixer không chỉ là một mạng MLP thông thường. Mỗi khối MLP được đặt trong một cấu trúc có ý nghĩa chuỗi thời gian rõ ràng: dữ liệu được hạ lấy mẫu, phân rã, trộn theo hướng phù hợp rồi mới dự báo. Nhờ vậy, mô hình vừa giữ được ưu thế tính toán của MLP, vừa khai thác được tri thức kinh điển về mùa vụ và xu hướng.

2 Ký hiệu đầu vào và đầu ra

Bài báo gốc ký hiệu chuỗi quá khứ là:

$$\mathbf{x} \in \mathbb{R}^{P \times C}, \quad (16)$$

trong đó P là độ dài lịch sử và C là số biến. Mục tiêu là sinh dự báo tương lai:

$$\hat{\mathbf{x}} \in \mathbb{R}^{F \times C}, \quad (17)$$

trong đó F là độ dài dự báo. Trong báo cáo này, cấu hình chính sử dụng $P = 96$; các tầm dự báo trong bảng định lượng gồm $F \in \{96, 192, 336, 720\}$.

Để thuận tiện, tập chuỗi đa quy mô được ký hiệu là:

$$\mathcal{X} = \{\mathbf{x}_0, \mathbf{x}_1, \dots, \mathbf{x}_M\}, \quad (18)$$

trong đó $\mathbf{x}_0 = \mathbf{x}$ là chuỗi gốc ở quy mô mịn nhất, còn $\mathbf{x}_M$ là chuỗi thô nhất.

3 Tạo chuỗi đa quy mô bằng average pooling

TimeMixer tạo chuỗi đa quy mô bằng cách hạ lấy mẫu liên tiếp. Với mỗi mức m , chuỗi $\mathbf{x}_m$ có độ dài:

$$\mathbf{x}_m \in \mathbb{R}^{\lfloor P/2^m \rfloor \times C}, \quad m = 0, 1, \dots, M. \quad (19)$$

Một dạng hạ lấy mẫu trung bình có thể biểu diễn như sau:

$$\mathbf{x}_m[i, c] = \frac{1}{2} \sum_{r=0}^1 \mathbf{x}_{m-1}[2i + r, c]. \quad (20)$$

Nếu $P = 96$ và $M = 3$, ta thu được các độ dài xấp xỉ 96, 48, 24 và 12. Các chuỗi ngắn hơn không còn giữ đầy đủ dao động cục bộ nhưng lại làm rõ cấu trúc vĩ mô. Đây là điểm quan trọng: hạ lấy mẫu không chỉ nhằm giảm kích thước tính toán, mà còn tạo ra các góc nhìn khác nhau về cùng một tín hiệu.

Sau khi tạo chuỗi đa quy mô, TimeMixer dùng lớp nhúng để đưa từng chuỗi vào không gian đặc trưng:

$$\mathcal{X}^0 = \text{Embed}(\mathcal{X}) = \{\mathbf{x}_0^0, \dots, \mathbf{x}_M^0\}, \quad (21)$$

$$\mathbf{x}_m^0 \in \mathbb{R}^{\lfloor P/2^m \rfloor \times d_{model}}. \quad (22)$$

Kích thước d_{model} là số chiều biểu diễn ẩn. Trong bài báo TimeMixer, cấu hình trên Electricity sử dụng $M = 3$, số khối PDM bằng 2 và $d_{model} = 16$ trong thiết lập thống nhất của paper.

4 Khối Past-Decomposable-Mixing

4.1 Mục tiêu của PDM

PDM là khối quan trọng nhất trong TimeMixer. Nếu chỉ trộn trực tiếp các chuỗi đa quy mô, mô hình vẫn có thể nhầm lẫn giữa dao động mùa vụ và xu hướng dài hạn. PDM giải quyết vấn đề này bằng cách phân rã từng quy mô thành hai thành phần riêng rồi mới trộn. Với tầng thứ ℓ , quá trình cập nhật tổng quát là:

$$\mathcal{X}^\ell = \text{PDM}(\mathcal{X}^{\ell-1}), \quad \ell = 1, 2, \dots, L_{pdm}. \quad (23)$$

4.2 Phân rã mùa vụ–xu hướng


Ở mỗi quy mô m , biểu diễn đầu vào được phân rã thành mùa vụ và xu hướng:

$$\mathbf{s}_m^\ell, \mathbf{t}_m^\ell = \text{SeriesDecomp}(\mathbf{x}_m^{\ell-1}), \quad m = 0, 1, \dots, M. \quad (24)$$

Một cách cài đặt phổ biến, cũng được sử dụng trong nhiều mô hình dự báo như Autoformer [6], là dùng trung bình trượt để xấp xỉ xu hướng:

$$\mathbf{t}_m^\ell = \text{MovingAvg}(\mathbf{x}_m^{\ell-1}), \quad \mathbf{s}_m^\ell = \mathbf{x}_m^{\ell-1} - \mathbf{t}_m^\ell. \quad (25)$$

Thành phần xu hướng thường biến đổi chậm và ít nhiều hơn. Thành phần mùa vụ chứa các dao động quanh xu hướng, bao gồm các chu kỳ lặp lại và các biến động ngắn hạn.



Hình 2: Minh họa phân rã chuỗi thành thành phần xu hướng và mùa vụ. TimeMixer thực hiện ý tưởng này ở từng quy mô trước khi trộn thông tin.

5 Seasonal Mixing theo hướng bottom-up

5.1 Trực giác

Thành phần mùa vụ ở quy mô thô thường được hình thành từ sự tổng hợp của các dao động chi tiết ở quy mô mịn. Chẳng hạn, chu kỳ tuần của phụ tải điện có thể được xem như sự kết hợp của nhiều chu kỳ ngày; chu kỳ ngày lại được tạo bởi các biến động theo giờ. Do đó, để học mùa vụ tốt, mô hình cần đưa thông tin chi tiết từ các quy mô mịn lên các quy mô thô.

5.2 Công thức

Với tập thành phần mùa vụ $\mathcal{S}^\ell = \{\mathbf{s}_0^\ell, \dots, \mathbf{s}_M^\ell\}$, TimeMixer cập nhật theo hướng bottom-up:

$$\mathbf{s}_m^\ell \leftarrow \mathbf{s}_m^\ell + \text{BottomUp}_m(\mathbf{s}_{m-1}^\ell), \quad m = 1, 2, \dots, M. \quad (26)$$

Trong đó $\text{BottomUp}_m(\cdot)$ là một MLP theo chiều thời gian, ánh xạ từ độ dài $\lfloor P/2^{m-1} \rfloor$ sang $\lfloor P/2^m \rfloor$. Cấu trúc cộng dư giúp mỗi quy mô giữ lại đặc trưng riêng, đồng thời nhận thêm thông tin mùa vụ từ quy mô chi tiết hơn.

6 Trend Mixing theo hướng top-down

6.1 Trực giác

Ngược lại với mùa vụ, xu hướng dài hạn cần tránh nhiều cục bộ. Quy mô thô, do đã qua average pooling, thường biểu diễn xu hướng rõ ràng hơn. Vì vậy, thông tin xu hướng nên được truyền từ quy mô thô xuống quy mô mịn để hướng dẫn các biểu diễn chi tiết không bị lệch khỏi mức nền dài hạn.

6.2 Công thức

Với tập xu hướng $\mathcal{T}^\ell = \{\mathbf{t}_0^\ell, \dots, \mathbf{t}_M^\ell\}$, TimeMixer cập nhật theo hướng top-down:

$$\mathbf{t}_m^\ell \leftarrow \mathbf{t}_m^\ell + \text{TopDown}_m(\mathbf{t}_{m+1}^\ell), \quad m = M-1, M-2, \dots, 0. \quad (27)$$

Trong đó $\text{TopDown}_m(\cdot)$ là MLP theo chiều thời gian, ánh xạ từ độ dài $\lfloor P/2^{m+1} \rfloor$ về $\lfloor P/2^m \rfloor$. Luồng top-down đóng vai trò đưa tri thức vĩ mô trở lại quy mô mịn, giúp dự báo giữ đúng xu hướng khi horizon dài.

7 Tổng hợp trong một khối PDM

Sau khi trộn mùa vụ và xu hướng, hai luồng được cộng lại và đưa qua một khối feed-forward:

$$\mathcal{X}^\ell = \mathcal{X}^{\ell-1} + \text{FeedForward}(\text{S-Mix}(\mathcal{S}^\ell) + \text{T-Mix}(\mathcal{T}^\ell)). \quad (28)$$

Khối feed-forward gồm các lớp tuyến tính và hàm kích hoạt GELU. Thành phần cộng dư giúp giảm nguy cơ mất thông tin khi xếp chồng nhiều khối PDM. Về mặt ý nghĩa, PDM có thể được xem như một cơ chế “lọc rồi trộn”: trước tiên tách chuỗi thành hai loại tín hiệu, sau đó trộn mỗi loại theo hướng phù hợp với bản chất của nó.

8 Khối Future-Multipredictor-Mixing

8.1 Động lực

Sau các khối PDM, mô hình có tập biểu diễn quá khứ ở nhiều quy mô:

$$\mathcal{X}^L = \{\mathbf{x}_0^L, \mathbf{x}_1^L, \dots, \mathbf{x}_M^L\}. \quad (29)$$

Nếu chỉ dùng quy mô mịn nhất để dự báo, mô hình có thể bỏ lỡ xu hướng dài hạn. Nếu chỉ dùng quy mô thô, dự báo có thể mất dao động chi tiết. FMM giải quyết vấn đề này bằng cách gán cho mỗi quy mô một bộ dự báo riêng.

8.2 Công thức FMM

Với mỗi quy mô m , mô hình sinh một dự báo thành phần:

$$\hat{\mathbf{x}}_m = \text{Predictor}_m(\mathbf{x}_m^L), \quad m = 0, 1, \dots, M. \quad (30)$$

Dự báo cuối cùng là tổng của các dự báo thành phần:

$$\hat{\mathbf{x}} = \sum_{m=0}^M \hat{\mathbf{x}}_m. \quad (31)$$

Cơ chế tổng hợp này có thể được hiểu như một ensemble có cấu trúc: mỗi predictor chuyên khai thác một quy mô thời gian, còn tổng cuối cùng kết hợp các năng lực bổ sung. Quy mô mịn đóng góp dao động chi tiết; quy mô thô đóng góp xu hướng và mức nền.

9 Thuật toán tổng quát của TimeMixer

Có thể tóm tắt quá trình suy diễn của TimeMixer như sau:

Bảng 1: Mô tả thuật toán tổng quát của TimeMixer.

Bước	Mô tả
1	Nhận chuỗi quá khứ $\mathbf{x} \in \mathbb{R}^{P \times C}$.
2	Tạo tập chuỗi đa quy mô $\mathcal{X} = \{\mathbf{x}_0, \dots, \mathbf{x}_M\}$ bằng average pooling.
3	Chiếu các chuỗi đa quy mô vào không gian ẩn bằng lớp embedding.
4	Với mỗi khối PDM, phân rã từng quy mô thành mùa vụ và xu hướng.
5	Trộn mùa vụ theo hướng bottom-up và trộn xu hướng theo hướng top-down.
6	Dùng feed-forward và kết nối dư để cập nhật biểu diễn đa quy mô.
7	Dùng FMM để tạo dự báo từ từng quy mô và cộng các dự báo thành phần.
8	Xuất dự báo cuối cùng $\hat{\mathbf{x}} \in \mathbb{R}^{F \times C}$.

10 Hàm mất mát

Trong thiết lập dự báo điểm, TimeMixer thường được huấn luyện bằng L2 Loss/MSE:

$$\mathcal{L}_{MSE} = \frac{1}{NHC} \sum_{i=1}^N \sum_{h=1}^H \sum_{c=1}^C (y_{i,h,c} - \hat{y}_{i,h,c})^2. \quad (32)$$

MSE phạt mạnh các sai số lớn, do đó phù hợp khi cần giảm các dự báo lệch xa. Tuy nhiên, nếu dữ liệu có nhiều spike hiếm gặp, MSE có thể làm mô hình ưu tiên giảm sai số trung bình hơn là dự báo đúng đỉnh cực trị. Đây là một hạn chế sẽ được thảo luận trong các chương sau.

11 Phân tích độ phức tạp

Một ưu điểm của TimeMixer là kiến trúc thuần MLP. Các lớp trộn theo thời gian không cần tính attention toàn cục với ma trận kích thước $P \times P$. Vì vậy, trong nhiều cấu hình, TimeMixer có chi phí bộ nhớ và thời gian thấp hơn các mô hình

Transformer dài hạn. Bài báo gốc cũng chỉ ra TimeMixer có hiệu quả runtime thuận lợi khi so sánh với nhiều baseline như PatchTST, TimesNet, Crossformer, FEDformer và Autoformer [1].

Tuy nhiên, cần lưu ý rằng MLP theo chiều thời gian vẫn có số tham số phụ thuộc vào độ dài chuỗi. Khi P rất lớn, việc dùng tuyến tính đầy đủ có thể làm tăng số tham số. Vì vậy, trong ứng dụng thực tế, cần cân bằng giữa số quy mô M , độ dài lookback P , số khối PDM và kích thước ẩn d_{model} .

12 Bằng chứng từ nghiên cứu ablation trong paper

Bài báo TimeMixer thực hiện ablation để kiểm chứng từng thành phần của mô hình. Kết quả chính cho thấy khi loại bỏ FMM, loại bỏ Seasonal Mixing, loại bỏ Trend Mixing hoặc đảo hướng trộn, hiệu năng đều giảm. Điều này củng cố ba kết luận:

- Trộn dự báo từ nhiều quy mô trong FMM là cần thiết vì mỗi quy mô có năng lực dự báo bổ sung.
- Phân rã mùa vụ–xu hướng trước khi trộn là cần thiết; trộn trực tiếp chuỗi đa quy mô kém hiệu quả hơn.
- Hướng trộn phải phù hợp với bản chất tín hiệu: seasonal nên bottom-up, trend nên top-down.

13 Ý nghĩa học thuật của TimeMixer

TimeMixer có ý nghĩa ở chỗ kết hợp được hai truyền thống nghiên cứu. Từ phân tích chuỗi thời gian cổ điển, mô hình kế thừa ý tưởng phân rã xu hướng và mùa vụ. Từ học sâu hiện đại, mô hình sử dụng MLP và biểu diễn đa tầng để học phi tuyến. Điểm quan trọng là hai hướng này không được ghép một cách cơ học, mà được tổ chức thành luồng thông tin có chủ đích. Vì vậy, TimeMixer vừa có khả năng dự báo mạnh, vừa có mức độ diễn giải kiến trúc tốt hơn nhiều mô hình hộp đen thuần túy.


IV THIẾT LẬP VÀ KẾT QUẢ THỰC NGHIỆM

1 Mô tả tập dữ liệu Electricity

Tập dữ liệu Electricity là một benchmark phổ biến trong các nghiên cứu dự báo chuỗi thời gian dài hạn [1, 8]. Dữ liệu ghi lại mức tiêu thụ điện của 321 khách hàng, được lấy mẫu theo tần suất một giờ. Mỗi khách hàng tương ứng với một biến trong chuỗi đa biến, do đó dữ liệu có dạng ma trận thời gian-kênh.

Theo mô tả trong bài báo TimeMixer, bộ Electricity được chia thành ba phần với kích thước lần lượt là (18317, 2633, 5261) cho tập huấn luyện, kiểm định và kiểm tra. Các tầm dự báo chuẩn thường được dùng là {96, 192, 336, 720}. Do dữ liệu có tần suất giờ, các horizon này tương ứng với dự báo khoảng 4 ngày, 8 ngày, 14 ngày và 30 ngày.

Đặc trưng quan trọng nhất của Electricity là tính chu kỳ ngày-đêm. Nhiều chuỗi có xu hướng đạt đỉnh vào các giờ hoạt động cao và giảm vào ban đêm. Ngoài ra, dữ liệu còn có chu kỳ tuần, do hành vi tiêu thụ điện trong ngày làm việc và cuối tuần thường khác nhau. Những đặc điểm này khiến Electricity trở thành một tập dữ liệu phù hợp để kiểm tra khả năng học mùa vụ, xu hướng và quan hệ đa biến của mô hình.



Hình 3: Mẫu hình tiêu thụ điện minh họa tính chu kỳ ngày-đêm trong dữ liệu Electricity.

2 Tiền xử lý dữ liệu và tạo mẫu

Tiền xử lý dữ liệu là bước quan trọng trước khi huấn luyện mô hình dự báo chuỗi thời gian. Khác với các bài toán hồi quy thông thường, dữ liệu chuỗi thời gian có quan hệ phụ thuộc theo thứ tự thời gian, vì vậy mọi thao tác tiền xử lý phải được thực hiện sao cho không sử dụng thông tin tương lai của tập kiểm định hoặc tập kiểm tra. Trong báo cáo này, quy trình tiền xử lý được xây dựng theo các bước chính: kiểm tra giá trị thiếu, kiểm tra tính đều của tần suất lấy mẫu, xem xét ngoại lai, tạo đặc trưng thời gian, chuẩn hóa dữ liệu, chia tập theo thứ tự thời gian và cuối cùng tạo các mẫu học có giám sát bằng cửa sổ trượt.

2.1 Kiểm tra giá trị thiếu

Bước đầu tiên là kiểm tra các giá trị thiếu trong toàn bộ bảng dữ liệu. Với bộ Electricity sử dụng trong thực nghiệm, dữ liệu gồm một cột thời gian `date` và 321 kênh phụ tải điện. Việc kiểm tra cho thấy dữ liệu không xuất hiện giá trị thiếu ở các kênh đầu vào. Do đó, nhóm không cần áp dụng các phương pháp điền khuyết như điền 0, nội suy tuyến tính, forward fill hoặc backward fill. Đây là điểm thuận lợi vì việc điền khuyết không phù hợp có thể làm biến dạng mẫu hình mùa vụ của chuỗi điện, đặc biệt ở các vùng có dao động mạnh.

Trong trường hợp áp dụng quy trình này cho một bộ dữ liệu khác có missing values, cách xử lý cần được lựa chọn theo nguyên nhân thiếu dữ liệu. Nếu thiếu ngắn hạn do lỗi ghi nhận, có thể dùng nội suy hoặc forward fill trong phạm vi cục bộ. Nếu thiếu kéo dài, cần cân nhắc loại bỏ kênh hoặc đánh dấu bằng biến chỉ báo thiếu dữ liệu. Tuy nhiên, các tham số hoặc quy tắc xử lý phải được xác định trên tập huấn luyện để hạn chế rò rỉ thông tin từ tương lai.

2.2 Kiểm tra tần suất lấy mẫu

Sau khi kiểm tra missing values, nhóm kiểm tra cột thời gian để đảm bảo chuỗi được lấy mẫu đều. Với dữ liệu Electricity, các quan sát liên tiếp cách nhau 1 giờ. Điều này phù hợp với thiết lập của mô hình, trong đó tham số tần suất được đặt theo dữ liệu giờ. Vì dữ liệu đã đều theo thời gian nên không cần thực hiện resampling lại trước

khi huấn luyện.

Việc kiểm tra tần suất lấy mẫu là cần thiết vì các mô hình như TimeMixer giả định rằng khoảng cách thời gian giữa hai quan sát liên tiếp là cố định. Nếu dữ liệu có mốc thời gian bị thiếu hoặc khoảng cách không đều, cùng một cửa sổ độ dài 96 có thể không còn tương ứng với bốn ngày lịch sử. Khi đó, mô hình sẽ học sai ý nghĩa của lookback và các đặc trưng mùa vụ theo giờ hoặc theo ngày.

2.3 Xem xét và xử lý outlier

Trong dữ liệu phụ tải điện, các giá trị bất thường có thể xuất phát từ hai nguyên nhân khác nhau. Một phần là nhiễu đo lường hoặc lỗi ghi nhận, nhưng một phần khác có thể là các đỉnh tải thật do thay đổi hành vi tiêu thụ, sự kiện đặc biệt hoặc thay đổi vận hành. Vì vậy, việc loại bỏ outlier một cách máy móc có thể làm mất các thông tin quan trọng đối với bài toán dự báo.

Trong thực nghiệm chính, nhóm không áp dụng clipping hoặc loại bỏ outlier trên dữ liệu Electricity nhằm giữ nguyên phân phối gốc của benchmark và đảm bảo khả năng so sánh với thiết lập của TimeMixer. Các giá trị lớn hoặc nhỏ bất thường nếu có sẽ được giữ lại và được mô hình học sau bước chuẩn hóa. Cách làm này phù hợp với mục tiêu đánh giá mô hình trên dữ liệu gốc. Tuy nhiên, trong các ứng dụng thực tế, nhóm có thể bổ sung bước kiểm tra outlier bằng các tiêu chí thống kê như IQR hoặc MAD trên tập huấn luyện, sau đó chỉ xử lý những điểm được xác định rõ là lỗi đo lường.

2.4 Tạo đặc trưng thời gian

Cột `date` không được đưa trực tiếp vào mô hình dưới dạng chuỗi ký tự mà được chuyển thành các đặc trưng thời gian. Với dữ liệu lấy mẫu theo giờ, các đặc trưng quan trọng gồm giờ trong ngày, thứ trong tuần, tháng và biến nhận biết cuối tuần. Các biến này giúp mô hình nhận diện các quy luật lặp lại theo lịch, ví dụ phụ tải ban ngày thường khác ban đêm, ngày làm việc khác cuối tuần và một số tháng có mức tiêu thụ điện cao hơn các tháng còn lại.

Trong pipeline của TimeMixer, khi sử dụng kiểu nhúng thời gian `timeF`, các đặc

trung lịch được sinh từ cột `date` và chuẩn hóa về miền giá trị ổn định. Với dữ liệu giờ, các đặc trưng này biểu diễn thông tin như giờ trong ngày, thứ trong tuần, ngày trong tháng và ngày trong năm. Đối với baseline XGBoost, nhóm sử dụng trực tiếp các biến lịch như `hour`, `day_of_week`, `month` và `is_weekend` để mô hình cây có thêm thông tin về mùa vụ.

Ngoài cách mã hóa lịch thông thường, các biến chu kỳ cũng có thể được biểu diễn bằng Fourier features. Ví dụ, với biến giờ trong ngày, ta có thể tạo hai biến:

$$hour_{sin} = \sin\left(\frac{2\pi \cdot hour}{24}\right), \quad hour_{cos} = \cos\left(\frac{2\pi \cdot hour}{24}\right). \quad (33)$$

Tương tự, chu kỳ tuần có thể được mã hóa bằng:

$$dow_{sin} = \sin\left(\frac{2\pi \cdot day_of_week}{7}\right), \quad dow_{cos} = \cos\left(\frac{2\pi \cdot day_of_week}{7}\right). \quad (34)$$

Cách mã hóa này giúp mô hình hiểu rằng giờ 23 và giờ 0 là hai thời điểm gần nhau trong chu kỳ ngày, mặc dù nếu biểu diễn bằng số nguyên thì chúng nằm ở hai đầu của thang đo. Trong báo cáo này, các đặc trưng thời gian được sử dụng chủ yếu để hỗ trợ mô hình học chu kỳ ngày-đêm và chu kỳ tuần của dữ liệu Electricity.

2.5 Chuẩn hóa dữ liệu

Sau khi tạo dữ liệu đầu vào, các biến phụ tải điện được chuẩn hóa bằng phương pháp chuẩn hóa Z-score. Với mỗi kênh, trung bình và độ lệch chuẩn chỉ được tính trên tập huấn luyện:

$$x' = \frac{x - \mu_{train}}{\sigma_{train}}. \quad (35)$$

Sau đó, cùng bộ tham số μ_{train} và σ_{train} được dùng để biến đổi tập huấn luyện, tập kiểm định và tập kiểm tra. Cách làm này đảm bảo rằng quá trình chuẩn hóa không sử dụng thông tin của tương lai, từ đó tránh hiện tượng rò rỉ dữ liệu.

Chuẩn hóa là cần thiết vì 321 kênh phụ tải có thể có mức nền và biên độ dao động khác nhau. Nếu không chuẩn hóa, các kênh có giá trị lớn có thể chi phối hàm mất mát, khiến mô hình học kém ở các kênh có thang đo nhỏ hơn. Ngoài chuẩn hóa ở

mức dữ liệu, TimeMixer còn sử dụng cơ chế chuẩn hóa theo từng cửa sổ trong mô hình, giúp ổn định quá trình học khi phân phối cục bộ của chuỗi thay đổi theo thời gian.

2.6 Chia tập theo thứ tự thời gian

Dữ liệu được chia theo đúng thứ tự thời gian thay vì chia ngẫu nhiên. Tập huấn luyện nằm ở phần đầu chuỗi, tập kiểm định nằm ở đoạn tiếp theo và tập kiểm tra nằm ở phần cuối. Cách chia này phản ánh đúng bối cảnh dự báo thực tế: mô hình chỉ được học từ quá khứ và phải dự báo các thời điểm xảy ra sau đó.

Theo thiết lập benchmark của Electricity trong TimeMixer, dữ liệu được chia xấp xỉ theo tỷ lệ 70% cho huấn luyện, 10% cho kiểm định và 20% cho kiểm tra. Tỷ lệ này tương ứng với kích thước được mô tả trong bài báo gốc và giúp kết quả trong báo cáo có thể so sánh với các nghiên cứu trước. Với các bộ dữ liệu mới không ràng buộc bởi benchmark, tỷ lệ 70% huấn luyện, 15% kiểm định và 15% kiểm tra cũng là một lựa chọn hợp lý để tăng kích thước tập kiểm định trong quá trình chọn mô hình.

Khi tạo tập kiểm định và tập kiểm tra, code lấy thêm một đoạn lịch sử có độ dài bằng lookback L ngay trước mốc bắt đầu của từng tập. Phần lịch sử này chỉ được dùng làm đầu vào quá khứ cho cửa sổ đầu tiên, còn nhãn dự báo vẫn nằm hoàn toàn trong vùng kiểm định hoặc kiểm tra. Do đó, cách tạo mẫu này không làm rò rỉ nhãn tương lai mà chỉ đảm bảo mô hình có đủ dữ liệu quá khứ để dự báo.

2.7 Tạo mẫu bằng cửa sổ trượt

Sau khi chuẩn hóa và chia tập, dữ liệu được chuyển thành các cặp đầu vào–đầu ra bằng cửa sổ trượt. Với mỗi vị trí thời gian t , mẫu học được tạo như sau:

$$\mathbf{X}^{(i)} = \mathbf{X}_{t-L+1:t}, \quad \mathbf{Y}^{(i)} = \mathbf{X}_{t+1:t+H}. \quad (36)$$

Trong đó, L là độ dài lookback và H là tầm dự báo. Trong báo cáo này, $L = 96$ được dùng cho tất cả mô hình. Với dữ liệu theo giờ, $L = 96$ tương ứng với bốn ngày lịch sử, đủ để mô hình quan sát nhiều chu kỳ ngày–đêm liên tiếp. Các tầm dự báo được xét gồm $H \in \{96, 192, 336, 720\}$, tương ứng với các bài toán dự báo từ ngắn hạn đến dài

hạn.

Với dữ liệu có $C = 321$ kênh, mỗi mẫu đầu vào của TimeMixer có kích thước $L \times C$, còn đầu ra có kích thước $H \times C$. Việc giữ cùng lookback cho Seasonal Naive, XGBoost và TimeMixer giúp đảm bảo so sánh công bằng, vì các mô hình đều nhận cùng lượng thông tin quá khứ. Điểm khác biệt nằm ở cách mỗi mô hình khai thác thông tin đó: Seasonal Naive lặp lại chu kỳ gần nhất, XGBoost dùng các đặc trưng trễ và thống kê từ cửa sổ, còn TimeMixer học biểu diễn đa quy mô trực tiếp từ chuỗi.

Bảng 2: Tóm tắt quy trình tiền xử lý dữ liệu trong thực nghiệm.

Bước tiền xử lý	Cách thực hiện trong báo cáo
Kiểm tra missing values	Dữ liệu Electricity không có giá trị thiếu, do đó không cần điền khuyết.
Kiểm tra tần suất lấy mẫu	Cột thời gian được kiểm tra và dữ liệu có tần suất đều 1 giờ/lần.
Xem xét outlier	Không clipping trong thực nghiệm chính để giữ nguyên phân phối gốc của benchmark.
Tạo đặc trưng thời gian	Sử dụng thông tin lịch như giờ trong ngày, thứ trong tuần, tháng, cuối tuần và các mã hóa chu kỳ khi cần.
Chuẩn hóa dữ liệu	Dùng Z-score, trong đó trung bình và độ lệch chuẩn chỉ được tính trên tập huấn luyện.
Chia tập dữ liệu	Chia theo thứ tự thời gian; thiết lập benchmark sử dụng xấp xỉ 70%/10%/20% cho train/validation/test.
Tạo mẫu học	Sử dụng cửa sổ trượt với lookback $L = 96$ và horizon $H \in \{96, 192, 336, 720\}$.

3 Thiết lập thực nghiệm

Các tầm dự báo được xét gồm:

$$H \in \{96, 192, 336, 720\}. \quad (37)$$

Ba mô hình được so sánh gồm:

- **Seasonal Naive:** mô hình thống kê cơ sở, dùng chu kỳ quá khứ để dự báo tương lai.
- **XGBoost:** mô hình cây tăng cường gradient, sử dụng đặc trưng trễ được tạo từ cửa sổ quan sát.
- **TimeMixer:** mô hình học sâu đa quy mô, sử dụng PDM và FMM để học biểu diễn quá khứ và dự báo tương lai.

Trong thiết lập chuẩn của bài báo TimeMixer, với Electricity, mô hình dùng $M = 3$ quy mô, 2 khối PDM, $d_{model} = 16$, learning rate 10^{-2} , batch size 32 và huấn luyện trong 20 epoch. Các thông số này cho thấy TimeMixer không cần một kiến trúc quá lớn để đạt kết quả tốt trên benchmark có 321 biến.

Bảng 3: Tóm tắt thiết lập thực nghiệm chính trong báo cáo.

Thành phần	Thiết lập
Dữ liệu	Electricity, dữ liệu tiêu thụ điện đa biến
Số biến	$C = 321$
Tần suất lấy mẫu	1 giờ/lần
Lookback	$L = 96$
Horizon	$H \in \{96, 192, 336, 720\}$
Mô hình so sánh	Seasonal Naive, XGBoost, TimeMixer
Chỉ số	MSE, MAE, RMSE
Trực quan hóa	Toàn bộ tập test với $lookback = 96$, $pred_len = 96$

4 Chỉ số đánh giá

Ba chỉ số được sử dụng gồm MSE, MAE và RMSE. Với N điểm đánh giá, giá trị thật y_i và dự báo $\hat{y}_i$, ta có:

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2, \quad (38)$$

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|, \quad (39)$$

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}. \quad (40)$$

MSE nhạy với sai số lớn, do đó phù hợp để phát hiện mô hình có dự báo lệch mạnh ở spike hoặc vùng biến động lớn. MAE đo sai số tuyệt đối trung bình và ít bị chi phối bởi outlier hơn. RMSE là căn của MSE nên có cùng đơn vị với dữ liệu gốc, thuận tiện khi diễn giải độ lệch dự báo.

5 Kết quả định lượng tổng quan

Bảng 4 trình bày kết quả đối sánh của ba mô hình trên dữ liệu Electricity. Các giá trị nhỏ hơn thể hiện mô hình tốt hơn.


Bảng 4: So sánh hiệu năng trên tập dữ liệu Electricity với cửa sổ quan sát $L = 96$.

Lookback	Horizon	TimeMixer			Seasonal Naive			XGBoost		
		MSE	MAE	RMSE	MSE	MAE	RMSE	MSE	MAE	RMSE
96	96	0.1526	0.2449	0.3906	0.3195	0.3295	0.5652	0.7905	0.6877	0.8891
	192	0.1656	0.2567	0.4069	0.3028	0.3275	0.5503	0.9910	0.7873	0.9955
	336	0.1854	0.2749	0.4306	0.3261	0.3469	0.5711	1.1582	0.8619	1.0762
	720	0.2236	0.3119	0.4729	0.3661	0.3783	0.6050	1.1618	0.8672	1.0779

Kết quả cho thấy TimeMixer đạt sai số thấp nhất ở cả bốn tầm dự báo. Ở $H = 96$, MSE của TimeMixer là 0.1526, thấp hơn Seasonal Naive (0.3195) và thấp hơn XGBoost (0.7905). Khi horizon tăng lên 720, TimeMixer vẫn duy trì MSE ở mức 0.2236, trong khi Seasonal Naive tăng lên 0.3661 và XGBoost đạt 1.1618.

6 Phân tích xu hướng sai số theo horizon

Hình 4 minh họa MSE của ba mô hình theo tầm dự báo. Đường của TimeMixer nằm thấp nhất ở mọi horizon. XGBoost có sai số cao và tăng nhanh khi horizon tăng. Seasonal Naive ổn định hơn XGBoost nhưng vẫn có sai số tuyệt đối cao hơn TimeMixer.




Hình 4: Xu hướng MSE theo tầm dự báo trên dữ liệu Electricity.

Ở $H = 96$, TimeMixer hưởng lợi từ khả năng học mùa vụ ngắn hạn ở quy mô mịn. Ở $H = 720$, lợi thế của TimeMixer đến từ quy mô thô và luồng trend mixing, giúp dự báo không trôi khỏi mức nền. Điều này phù hợp với thiết kế của mô hình: seasonal mixing giữ dao động chi tiết, còn trend mixing giữ định hướng dài hạn.

7 Mức cải thiện tương đối của TimeMixer

Để thấy rõ hơn lợi ích của TimeMixer, ta tính mức giảm MSE so với baseline:

$$\text{Reduction} = \frac{\text{MSE}_{\text{baseline}} - \text{MSE}_{\text{TimeMixer}}}{\text{MSE}_{\text{baseline}}} \times 100\%. \quad (41)$$



Hình 5: Mức giảm MSE của TimeMixer so với Seasonal Naive và XGBoost.

Bảng 5: Mức giảm MSE của TimeMixer so với từng baseline.

Horizon	Giảm so với Seasonal Naive	Giảm so với XGBoost
96	52.24%	80.70%
192	45.31%	83.29%
336	43.15%	83.99%
720	38.92%	80.75%

Bảng 5 cho thấy TimeMixer giảm MSE hơn 38% so với Seasonal Naive ở mọi horizon và hơn 80% so với XGBoost ở phần lớn horizon. Điều này rất đáng chú ý vì Seasonal Naive là baseline mạnh trên dữ liệu có mùa vụ rõ. Việc TimeMixer vượt rõ Seasonal Naive cho thấy mô hình không chỉ sao chép chu kỳ, mà còn học được sự điều chỉnh mức nền và quan hệ đa quy mô.

8 Phân tích riêng từng mô hình

8.1 TimeMixer

TimeMixer có sai số thấp nhất và tăng chậm khi horizon dài hơn. MSE tăng từ 0.1526 tại $H = 96$ lên 0.2236 tại $H = 720$. Sự tăng này là tự nhiên vì dự báo xa khó

hơn, nhưng mức tăng không quá lớn. Điều này cho thấy FMM và PDM giúp mô hình duy trì cấu trúc chuỗi ngay cả khi dự báo dài hạn.

8.2 Seasonal Naive

Seasonal Naive có kết quả tốt hơn XGBoost, đặc biệt ở horizon dài. Kết quả này phản ánh tính mùa vụ rất mạnh của Electricity. Tuy nhiên, Seasonal Naive không có khả năng học mức nền mới. Nếu chuỗi thực tế thay đổi xu hướng, mô hình vẫn chỉ lặp lại quá khứ, dẫn đến sai số cao hơn TimeMixer.

8.3 XGBoost

XGBoost có sai số lớn nhất. Lý do chính là mô hình cây không tự nhiên nắm bắt cấu trúc tuần tự và chu kỳ nếu không có đặc trưng thời gian đủ mạnh. Ngoài ra, dự báo dạng cây thường bị rời rạc, khó tái tạo dao động mượt và dễ kéo dự báo về mức trung bình. Điều này sẽ được thể hiện rõ hơn trong phần trực quan hóa ở Chương 5.

9 Liên hệ với kết quả trong bài báo gốc

Trong bài báo TimeMixer, mô hình được đánh giá trên nhiều benchmark dài hạn như Weather, Solar-Energy, Electricity, Traffic và ETT. Với thiết lập thống nhất, TimeMixer đạt kết quả tốt trên Electricity và nhiều tập dữ liệu khác, đồng thời có hiệu quả tính toán thuận lợi nhờ kiến trúc thuần MLP [1]. Kết quả trong báo cáo này phù hợp với kết luận đó: khi dữ liệu chứa nhiều mẫu hình ở các thang thời gian khác nhau, cơ chế decomposable multiscale mixing đem lại lợi ích rõ ràng.

10 Kết luận chương

Chương này đã mô tả dữ liệu Electricity, thiết lập thực nghiệm, chỉ số đánh giá và kết quả định lượng. Kết quả cho thấy TimeMixer vượt trội so với cả Seasonal Naive và XGBoost. Tuy nhiên, để hiểu sâu hơn mô hình sai ở đâu và sai theo kiểu gì, cần bổ sung phân tích trực quan trên toàn bộ tập kiểm tra. Nội dung này được trình bày trong chương tiếp theo.

V PHÂN TÍCH KHẢ NĂNG DIỄN GIẢI VÀ TRỰC QUAN HÓA DỮ LIỆU

1 Vai trò của trực quan hóa trong đánh giá mô hình

Các chỉ số MSE, MAE và RMSE giúp lượng hóa sai số trung bình, nhưng không thể mô tả đầy đủ hình dạng của dự báo. Hai mô hình có cùng MSE vẫn có thể sai theo hai cách rất khác nhau: một mô hình bám đúng xu hướng nhưng làm vượt quá mức, mô hình khác giữ đúng biên độ nhưng lệch pha mùa vụ. Vì vậy, trực quan hóa đường dự báo trên tập kiểm tra là bước cần thiết để đánh giá khả năng mô hình hóa chuỗi thời gian.

Trong chương này, báo cáo sử dụng ba file ảnh dự báo toàn bộ tập test với cấu hình $lookback = 96$ và $pred_len = 96$. Trục hoành biểu diễn thứ tự thời gian trên tập kiểm tra, còn trục tung biểu diễn giá trị biến mục tiêu. Đường ground truth là giá trị thực tế; đường prediction là dự báo của từng mô hình. Việc quan sát toàn bộ tập kiểm tra giúp đánh giá tính ổn định của mô hình trong thời gian dài, thay vì chỉ nhìn một vài đoạn ngắn.


2 Các tiêu chí phân tích định tính

Khi đọc một đồ thị dự báo chuỗi thời gian, báo cáo tập trung vào năm tiêu chí:

1. **Bám mức nền:** dự báo có đi theo xu hướng trung bình của chuỗi hay không.
2. **Giữ nhịp mùa vụ:** dự báo có duy trì chu kỳ lặp lại và đúng pha hay không.
3. **Tái tạo biên độ:** dự báo có tạo được độ cao của đỉnh và độ sâu của đáy hay bị làm phẳng.
4. **Độ mượt:** đường dự báo có liên tục, ổn định hay bị gãy đoạn/rời rạc.
5. **Xử lý spike:** mô hình phản ứng thế nào với các điểm tăng vọt hoặc giảm mạnh bất thường.

Năm tiêu chí này bổ sung cho các chỉ số định lượng và giúp giải thích tại sao một mô hình có MSE thấp hơn mô hình khác.

3 TimeMixer trên toàn bộ tập kiểm tra




Hình 6: Dự báo TimeMixer trên toàn bộ tập kiểm tra với $lookback = 96$ và $pred_len = 96$.

Hình 6 cho thấy TimeMixer tái tạo khá tốt cấu trúc tổng thể của chuỗi. Đường dự báo bám sát mức nền của ground truth trong phần lớn tập kiểm tra. Các dao động tuần hoàn được giữ tương đối rõ, cho thấy mô hình học được nhịp mùa vụ chính của dữ liệu điện năng. Đây là kết quả phù hợp với thiết kế PDM: thành phần seasonal ở quy mô mịn giúp mô hình duy trì các dao động lặp lại.

Ở nhiều vùng ổn định, dự báo của TimeMixer gần như đi song song với ground truth. Điều này cho thấy mô hình không chỉ học mức trung bình mà còn học được hình dạng dao động. Khi chuỗi có xu hướng tăng hoặc giảm chậm, đường dự báo cũng có xu hướng dịch chuyển theo, thay vì lặp lại cứng nhắc một mẫu cũ. Khả năng này có thể đến từ luồng trend mixing top-down, trong đó quy mô thô cung cấp tri thức về mức nền dài hạn.

Tuy nhiên, TimeMixer vẫn làm trơn một số đỉnh cực trị. Các spike rất cao không được tái tạo hoàn toàn về biên độ. Hiện tượng này có thể xuất phát từ hai nguyên nhân. Thứ nhất, average pooling trong nhánh đa quy mô có xu hướng làm mượt tín hiệu, khiến mô hình ưu tiên mẫu hình ổn định. Thứ hai, khi huấn luyện bằng MSE trên toàn bộ tập dữ liệu, mô hình thường học dự báo kỳ vọng có điều kiện; các sự kiện hiếm có thể bị kéo về mức trung bình để giảm sai số tổng thể. Vì vậy, TimeMixer phù hợp với dự báo vận hành ổn định, nhưng nếu mục tiêu là cảnh báo đỉnh tải cực đoạn, cần bổ sung cơ chế xử lý spike.

4 Seasonal Naive trên toàn bộ tập kiểm tra




Hình 7: Dự báo Seasonal Naive trên toàn bộ tập kiểm tra với $lookback = 96$ và $pred_len = 96$.

Hình 7 cho thấy Seasonal Naive giữ được chu kỳ lặp lại khá rõ. Đây là điều dễ hiểu vì mô hình dự báo bằng cách sao chép giá trị ở cùng pha mùa vụ trong quá khứ. Khi dữ liệu thực tế có chu kỳ ổn định, dự báo Seasonal Naive có thể bám tương đối tốt nhịp dao động. Điều này giải thích tại sao Seasonal Naive có kết quả định lượng tốt hơn XGBoost trong Chương 4.

Điểm mạnh của Seasonal Naive là tính ổn định và khả năng bảo toàn pha mùa vụ. Mô hình không bị huấn luyện sai, không cần tối ưu tham số và có thể hoạt động tốt ngay cả khi dữ liệu huấn luyện không lớn. Tuy nhiên, hạn chế của nó cũng rất rõ. Khi mức nền thực tế thay đổi, Seasonal Naive vẫn tiếp tục sao chép mẫu quá khứ. Do đó, dự báo dễ bị lệch biên độ hoặc lệch mức nền. Nếu chuỗi có sự thay đổi do thời tiết, ngày nghỉ hoặc xu hướng mới, mô hình không có cơ chế tự điều chỉnh.

Một vấn đề khác là Seasonal Naive có thể sao chép cả nhiễu. Nếu ở chu kỳ trước có một điểm bất thường, mô hình có thể đưa điểm bất thường đó vào dự báo dù tương lai không lặp lại sự kiện đó. Ngược lại, nếu tương lai có spike nhưng quá khứ cùng pha không có, mô hình sẽ bỏ lỡ spike. Vì vậy, Seasonal Naive là baseline có ý nghĩa nhưng không đủ cho các hệ thống cần phản ứng linh hoạt.

5 XGBoost trên toàn bộ tập kiểm tra



Hình 8: Dự báo XGBoost trên toàn bộ tập kiểm tra với $lookback = 96$ và $pred_len = 96$.

Hình 8 cho thấy dự báo của XGBoost có dạng rời rạc và nhiều đoạn gãy hơn so với TimeMixer và Seasonal Naive. Đây là đặc trưng thường gặp của mô hình cây quyết định. Cây chia không gian đặc trưng thành các vùng; mỗi vùng trả về một giá trị tương ứng với lá cây. Khi kết hợp nhiều cây, đường dự báo có thể phức tạp hơn, nhưng vẫn thường thiếu sự mượt mà của một mô hình học biểu diễn tuần tự.

XGBoost có xu hướng kéo dự báo về mức trung bình và khó tái tạo đầy đủ biên độ dao động. Với dữ liệu phụ tải điện, tín hiệu có tính tuần hoàn liên tục; các đỉnh và đáy xuất hiện theo nhịp khá đều. Nếu XGBoost không được cung cấp đặc trưng thời gian đủ mạnh như giờ trong ngày, ngày trong tuần hoặc embedding chu kỳ, mô hình phải suy luận chu kỳ từ các giá trị trễ. Điều này khó hơn đáng kể, đặc biệt khi dự báo nhiều bước.

Dạng dự báo của XGBoost cũng cho thấy hạn chế trong dự báo dài hạn. Khi horizon lớn, mô hình không có cơ chế nội tại để duy trì pha mùa vụ và xu hướng. Các dự báo có thể trở nên phẳng hoặc lệch biên độ. Điều này phù hợp với bảng kết quả định lượng: XGBoost có MSE và MAE cao nhất ở tất cả các horizon.

6 So sánh định tính ba mô hình

Bảng 6 tóm tắt nhận xét định tính từ ba hình trực quan.


Bảng 6: So sánh định tính ba mô hình trên hình dự báo toàn bộ tập test.

Tiêu chí	TimeMixer	Seasonal Naive	XGBoost
Bám mức nền	Tốt, có khả năng điều chỉnh theo xu hướng chậm	Trung bình, dễ lệch khi mức nền thay đổi	Yếu hơn, thường kéo về mức trung bình
Giữ nhịp mùa vụ	Tốt, học được dao động chu kỳ từ quy mô mịn	Tốt khi chu kỳ ổn định vì sao chép quá khứ	Hạn chế nếu thiếu đặc trưng thời gian
Tái tạo biên độ	Khá tốt nhưng làm trơn spike lớn	Phụ thuộc vào chu kỳ quá khứ	Thường làm phẳng biên độ
Độ mượt dự báo	Tương đối mượt và ổn định	Có tính lặp lại đều nhưng thiếu thích ứng	Rời rạc, dễ có đoạn gãy
Xử lý spike	Có xu hướng làm trơn	Chỉ đúng nếu spike lặp lại theo mùa vụ	Thường kéo spike về mức trung bình

Nhìn tổng thể, TimeMixer là mô hình cân bằng nhất. Seasonal Naive giữ chu kỳ tốt nhưng thiếu khả năng thích ứng. XGBoost có năng lực học phi tuyến nhưng không phù hợp nếu không có biểu diễn thời gian đủ tốt. TimeMixer vượt lên vì kết hợp được hai yếu tố: học mùa vụ từ quy mô mịn và học xu hướng từ quy mô thô.

7 Phân tích miền tần số

Một cách khác để hiểu khả năng học chu kỳ là chuyển chuỗi từ miền thời gian sang miền tần số bằng biến đổi Fourier nhanh (FFT). Trong miền tần số, các chu kỳ lặp lại sẽ xuất hiện dưới dạng các đỉnh năng lượng tại những tần số nhất định. Với dữ liệu theo giờ, các chu kỳ quan trọng thường liên quan đến 24 giờ, 12 giờ hoặc chu kỳ tuần.



Hình 9: Minh họa phân tích phổ tần số FFT để quan sát các thành phần chu kỳ trong chuỗi.

Hình 9 minh họa ý tưởng phân tích phổ tần số. Nếu dự báo giữ được các đỉnh phổ chính, mô hình đã học được mùa vụ quan trọng. Nếu phổ bị suy giảm quá mạnh ở tần số mùa vụ, dự báo có thể đúng mức trung bình nhưng mất nhịp dao động. Nếu phổ có quá nhiều năng lượng ở tần số cao, mô hình có thể đang học nhiễu.

TimeMixer có lợi thế trong phân tích tần số vì kiến trúc của nó tách trend và seasonal trước khi trộn. Luồng seasonal mixing tập trung vào dao động chi tiết, tương ứng với các thành phần tần số cao hơn. Luồng trend mixing tập trung vào mức nền, tương ứng với thành phần tần số thấp. Do đó, mô hình có cơ chế tự nhiên để cân bằng giữa hai miền tín hiệu.

8 Diễn giải vai trò của PDM từ hình dự báo

Từ hình TimeMixer, có thể liên hệ từng đặc điểm dự báo với từng thành phần kiến trúc:

- Các dao động lặp lại tương đối đúng pha phản ánh đóng góp của quy mô mịn và seasonal mixing.
- Mức nền dự báo không bị trôi mạnh phản ánh đóng góp của quy mô thô và trend

mixing.

- Đường dự báo mượt phản ánh cơ chế tổng hợp nhiều predictor trong FMM, giúp giảm phụ thuộc vào một quy mô duy nhất.
- Việc spike bị làm trơn cho thấy giới hạn của dự báo điểm và hàm mất mát MSE khi xử lý sự kiện hiếm.

Như vậy, TimeMixer có mức độ diễn giải kiến trúc tương đối tốt. Ta không cần đọc từng trọng số MLP, nhưng có thể hiểu vai trò của các luồng thông tin trong việc tạo ra hình dạng dự báo.

9 Kết luận chương

Thực quan hóa toàn bộ tập kiểm tra củng cố kết quả định lượng ở Chương 4. TimeMixer không chỉ có sai số thấp hơn mà còn tạo ra đường dự báo hợp lý hơn: bám mức nền, giữ nhịp mùa vụ và ổn định trong thời gian dài. Seasonal Naive chứng minh giá trị của tri thức mùa vụ nhưng thiếu khả năng thích ứng. XGBoost thể hiện hạn chế rõ rệt trong việc tái tạo chuỗi tuần hoàn mượt. Những quan sát này là cơ sở cho phần thảo luận sâu ở Chương 6.

VI THẢO LUẬN VÀ ĐÁNH GIÁ CHUYÊN SÂU

1 Tại sao Seasonal Naive có thể vượt XGBoost?

Một kết quả đáng chú ý trong thực nghiệm là Seasonal Naive, dù rất đơn giản, lại vượt XGBoost trên dữ liệu Electricity. Điều này không mâu thuẫn với trực giác học máy. Nó phản ánh một nguyên lý quan trọng trong dự báo chuỗi thời gian: *tri thức tiên nghiệm về cấu trúc dữ liệu đôi khi quan trọng hơn độ phức tạp của thuật toán*. Nếu chuỗi có mùa vụ mạnh và ổn định, việc sao chép giá trị cùng pha trong quá khứ có thể tạo ra một dự báo rất khó bị đánh bại bởi các mô hình không được thiết kế chuyên biệt cho thời gian.

Seasonal Naive mã hóa trực tiếp giả định rằng hành vi tiêu thụ điện lặp lại theo chu kỳ. Với dữ liệu điện năng, chu kỳ ngày–đêm và chu kỳ tuần thường là hai nguồn

biến động lớn. Trong khi đó, XGBoost xem mỗi mẫu như một vector đặc trưng rời rạc. Nếu không có đặc trưng thời gian đủ rõ, mô hình cây phải tự phát hiện tính chu kỳ từ các giá trị trễ. Nhiệm vụ này khó hơn nhiều, nhất là khi dự báo đa bước.

Kết quả này cũng là một lời nhắc phương pháp luận: khi làm dự báo chuỗi thời gian, cần luôn xây dựng các baseline thống kê có ý nghĩa. Một mô hình học sâu hoặc học máy chỉ thực sự thuyết phục nếu vượt được baseline phù hợp với bản chất dữ liệu.

2 Giới hạn của XGBoost trong dự báo chuỗi dài

XGBoost là mô hình rất mạnh trong dữ liệu bảng, nhưng có ba hạn chế khi chuyển sang chuỗi thời gian. Thứ nhất, mô hình không có bộ nhớ tuần tự tự nhiên. Tất cả quan hệ thời gian phải được đưa vào bằng đặc trưng trễ hoặc đặc trưng lịch. Thứ hai, cây quyết định dự báo theo các vùng của không gian đặc trưng, nên đường dự báo thường không mượt và không bảo toàn tốt cấu trúc phổ của chuỗi. Thứ ba, mô hình cây không ngoại suy tốt. Khi xu hướng tương lai vượt khỏi vùng dữ liệu đã học, cây không thể tạo ra một xu hướng mới một cách tự nhiên.

Trong dự báo dài hạn, các hạn chế này trở nên nghiêm trọng hơn. Horizon càng dài, mô hình càng cần duy trì pha mùa vụ, biên độ dao động và xu hướng mức nền. XGBoost có thể khớp tốt các quan hệ phi tuyến cục bộ trong tập huấn luyện, nhưng điều đó không đảm bảo mô hình tái tạo được quỹ đạo thời gian dài. Đây là lý do MSE của XGBoost tăng nhanh và duy trì ở mức cao trong kết quả thực nghiệm.

3 Ưu thế của TimeMixer trong dữ liệu đa quy mô

3.1 Không ép mọi tín hiệu vào một quy mô

Ưu thế đầu tiên của TimeMixer là mô hình không xử lý toàn bộ chuỗi ở một độ phân giải duy nhất. Khi dùng nhiều quy mô, mô hình có thể nhìn thấy cùng một tín hiệu dưới nhiều mức chi tiết. Quy mô mịn giữ các dao động giờ/ngày; quy mô thô làm rõ mức nền và xu hướng dài hạn. Điều này đặc biệt phù hợp với dữ liệu phụ tải điện, nơi các dao động ngắn hạn và dài hạn cùng tồn tại.

3.2 Phân rã trước khi trộn

Ưu thế thứ hai là PDM phân rã chuỗi thành mùa vụ và xu hướng trước khi trộn. Nếu không phân rã, mô hình có thể đưa nhiều cục bộ vào luồng xu hướng hoặc làm mất dao động mùa vụ khi làm trơn. Việc tách hai thành phần giúp mô hình định tuyến thông tin hợp lý: seasonal đi từ mịn lên thô, trend đi từ thô xuống mịn. Đây là điểm khác biệt then chốt so với các mô hình chỉ sử dụng hạ lấy mẫu hoặc chỉ sử dụng MLP thông thường.

3.3 Tổng hợp nhiều bộ dự báo

Ưu thế thứ ba là FMM sử dụng nhiều predictor. Trong dự báo, không có một quy mô duy nhất luôn tốt nhất. Quy mô mịn tốt cho dao động chi tiết nhưng dễ bị nhiễu. Quy mô thô tốt cho xu hướng nhưng mất chi tiết. FMM cho phép mô hình tổng hợp các dự báo thành phần để đạt cân bằng. Nhờ vậy, TimeMixer có thể vừa giữ nhịp mùa vụ vừa không trôi xu hướng khi horizon dài.

4 Mối quan hệ giữa TimeMixer và các mô hình Transformer

Các mô hình Transformer như Informer, Autoformer, FEDformer hoặc PatchTST đã tạo ra nhiều tiến bộ trong dự báo chuỗi thời gian dài hạn. Điểm mạnh của Transformer là attention có khả năng mô hình hóa phụ thuộc xa. Tuy nhiên, attention toàn cục thường có chi phí bộ nhớ lớn khi độ dài chuỗi tăng. Ngoài ra, trong chuỗi thời gian, không phải mọi phụ thuộc đều cần học bằng attention; nhiều cấu trúc quan trọng đã có dạng mùa vụ, xu hướng và đa quy mô.

TimeMixer cho thấy một hướng khác: thay vì dùng attention để tìm mọi quan hệ, mô hình dùng cấu trúc đa quy mô và MLP để trộn thông tin có định hướng. Cách tiếp cận này giảm chi phí tính toán trong nhiều thiết lập và vẫn đạt hiệu quả cao. Điều này không có nghĩa Transformer không còn giá trị, mà cho thấy trong dự báo chuỗi thời gian, kiến trúc đơn giản nhưng đúng cấu trúc dữ liệu có thể cạnh tranh với kiến trúc phức tạp hơn.

5 Ý nghĩa thực tiễn trong dự báo phụ tải điện

Trong hệ thống điện, dự báo phụ tải có thể phục vụ nhiều nhiệm vụ như lập kế hoạch phát điện, tối ưu vận hành lưới, phát hiện rủi ro quá tải và điều phối nguồn năng lượng tái tạo. Một mô hình dự báo cần đáp ứng ba yêu cầu: chính xác, ổn định và có thể triển khai với chi phí hợp lý. TimeMixer có tiềm năng ở cả ba khía cạnh.

Về độ chính xác, kết quả định lượng cho thấy TimeMixer có sai số thấp nhất. Về độ ổn định, trực quan hóa cho thấy đường dự báo của TimeMixer bám được mức nền và nhịp mùa vụ trên toàn bộ tập test. Về chi phí, kiến trúc thuần MLP giúp mô hình tránh một phần chi phí của attention. Tuy nhiên, khi triển khai thực tế, cần đánh giá thêm độ trễ suy diễn, khả năng cập nhật mô hình và độ bền vững khi phân phối dữ liệu thay đổi.

6 Các dạng sai số còn tồn tại

Dù TimeMixer vượt trội trong kết quả, mô hình vẫn có một số dạng sai số cần lưu ý:

- **Làm trơn spike:** mô hình có xu hướng dự báo thấp hơn các đỉnh cực trị.
- **Sai số tại điểm chuyển pha:** khi chuỗi chuyển từ trạng thái thấp sang cao hoặc ngược lại, dự báo có thể chậm hơn thực tế.
- **Sai số do yếu tố ngoại sinh:** nếu phụ tải thay đổi vì thời tiết hoặc ngày lễ, mô hình chỉ dùng lịch sử tiêu thụ có thể phản ứng chưa đủ nhanh.
- **Bất định chưa được lượng hóa:** mô hình dự báo điểm không cung cấp khoảng tin cậy cho quyết định vận hành.

Những hạn chế này không phủ nhận giá trị của TimeMixer, mà chỉ ra hướng cải tiến để mô hình phù hợp hơn với ứng dụng thực tế.

7 Hạn chế của báo cáo

Báo cáo tập trung vào dữ liệu Electricity và ba mô hình đại diện. Phạm vi này phù hợp với yêu cầu môn học, nhưng chưa đủ để kết luận tuyệt đối cho mọi loại chuỗi

thời gian. Các tập dữ liệu có ít mùa vụ, nhiều đứt gãy cấu trúc hoặc chịu tác động ngoại sinh mạnh có thể tạo ra kết quả khác. Ngoài ra, báo cáo chủ yếu đánh giá dự báo điểm bằng MSE, MAE và RMSE; chưa đánh giá dự báo xác suất, độ phủ khoảng dự báo hoặc chi phí triển khai thời gian thực.

Một hạn chế khác là phân trực quan hóa tập trung vào một biến mục tiêu đại diện. Với dữ liệu đa biến 321 kênh, mỗi kênh có thể có mẫu hình riêng. Để đánh giá toàn diện hơn, cần phân tích phân phối sai số theo kênh, nhóm các kênh có hành vi giống nhau và kiểm tra mô hình trên các kênh có mức tiêu thụ bất thường.

8 Bài học phương pháp luận

Từ toàn bộ kết quả có thể rút ra ba bài học. Thứ nhất, baseline đơn giản nhưng đúng bản chất dữ liệu có thể rất mạnh. Thứ hai, mô hình học máy truyền thống cần kỹ nghệ đặc trưng thời gian cẩn thận nếu muốn cạnh tranh trong dự báo chuỗi. Thứ ba, một kiến trúc học sâu hiệu quả không nhất thiết phải phức tạp nhất; quan trọng là kiến trúc đó tổ chức đúng luồng thông tin. TimeMixer là một ví dụ tiêu biểu: mô hình kết hợp phân rã, đa quy mô và MLP để giải quyết bài toán dự báo dài hạn.

VII ĐỀ XUẤT CẢI TIẾN PHƯƠNG PHÁP

1 Mục tiêu cải tiến

Các kết quả ở Chương 4 và Chương 5 cho thấy TimeMixer có hiệu năng tốt trên dữ liệu Electricity. Tuy nhiên, để đưa mô hình gần hơn với ứng dụng thực tế trong hệ thống điện, cần xem xét thêm ba vấn đề: ảnh hưởng của biến ngoại sinh, khả năng xử lý outlier/spike và nhu cầu dự báo bất định. Chương này đề xuất một số hướng cải tiến có thể triển khai trong các nghiên cứu tiếp theo.

2 Tích hợp biến ngoại sinh

2.1 Động lực

Phụ tải điện không chỉ phụ thuộc vào lịch sử tiêu thụ. Nhiệt độ, độ ẩm, ngày nghỉ, sự kiện xã hội, lịch sản xuất và giá điện đều có thể làm thay đổi nhu cầu. Ví dụ,

trong ngày nắng nóng, nhu cầu điều hòa tăng mạnh; trong kỳ nghỉ, phụ tải khu công nghiệp có thể giảm nhưng phụ tải dân cư có thể tăng. Nếu mô hình chỉ dùng biến nội sinh, nó có thể dự báo tốt chu kỳ thông thường nhưng phản ứng chậm với các điểm uốn do ngoại cảnh.

2.2 Mở rộng đầu vào

Ký hiệu ma trận biến ngoại sinh là:

$$\mathbf{Z} \in \mathbb{R}^{(P+F) \times d}, \quad (42)$$

trong đó d là số biến ngoại sinh. Một số biến ngoại sinh có thể biết trước trong tương lai, như giờ trong ngày, ngày trong tuần, ngày lễ hoặc dự báo thời tiết. Ta có thể nhúng các biến này vào không gian đặc trưng:

$$\mathbf{E}^z = \text{Embed}_z(\mathbf{Z}). \quad (43)$$

Sau đó, biểu diễn ngoại sinh có thể được ghép vào biểu diễn chuỗi chính ở từng quy mô:

$$\tilde{\mathbf{x}}_m = \text{Concat}(\mathbf{x}_m, \mathbf{E}_m^z). \quad (44)$$

Cách làm này cho phép PDM trộn mùa vụ và xu hướng trong bối cảnh cụ thể, thay vì chỉ dựa vào lịch sử tiêu thụ.

2.3 Điều kiện hóa trọng số trộn

Một hướng nâng cao là dùng biến ngoại sinh để điều tiết biểu diễn ẩn. Từ covariate, mô hình sinh vector cổng:

$$\mathbf{g}_t = \sigma(W_z \mathbf{z}_t + b_z), \quad (45)$$

rồi dùng vector này để điều chỉnh đặc trưng:

$$\mathbf{h}'_t = \mathbf{g}_t \odot \mathbf{h}_t. \quad (46)$$

Khi đó, cùng một mẫu mùa vụ có thể được điều chỉnh khác nhau trong ngày nóng, ngày lạnh, ngày thường hoặc ngày nghỉ. Đây là hướng phù hợp với phụ tải điện vì mối quan hệ giữa lịch sử tiêu thụ và tương lai không hoàn toàn cố định.

3 Cải tiến hàm mất mát

3.1 Huber Loss

MSE phạt mạnh sai số lớn, nhưng cũng nhạy với outlier. Nếu dữ liệu có nhiều đo lường hoặc spike hiếm, MSE có thể khiến mô hình bị kéo bởi các điểm cực đoan. Huber Loss là một lựa chọn cân bằng giữa MSE và MAE:

$$L_{\delta}(y, \hat{y}) = \begin{cases} \frac{1}{2}(y - \hat{y})^2, & \text{nếu } |y - \hat{y}| \leq \delta, \\ \delta|y - \hat{y}| - \frac{1}{2}\delta^2, & \text{nếu } |y - \hat{y}| > \delta. \end{cases} \quad (47)$$

Với sai số nhỏ, Huber hoạt động như MSE; với sai số lớn, nó chuyển sang dạng tuyến tính như MAE. Điều này giúp giảm ảnh hưởng của outlier cực đoan nhưng vẫn giữ khả năng tối ưu mượt.

3.2 Quantile Loss

Trong vận hành thực tế, một giá trị dự báo điểm chưa đủ. Người quản lý cần biết khoảng bất định để đánh giá rủi ro vượt tải. Quantile Loss cho phép mô hình dự báo các phân vị khác nhau. Với mức phân vị $q \in (0, 1)$:

$$L_q(y, \hat{y}) = \max(q(y - \hat{y}), (q - 1)(y - \hat{y})). \quad (48)$$

Nếu huấn luyện đồng thời $q = 0.1$, $q = 0.5$ và $q = 0.9$, mô hình có thể đưa ra trung vị dự báo và khoảng bất định 80%. Đây là bước quan trọng để chuyển TimeMixer từ dự báo điểm sang dự báo xác suất.

4 Bổ sung nhánh phát hiện spike

Các spike trong phụ tải điện có thể là nhiễu hoặc sự kiện thật. Nếu mô hình luôn làm trơn spike, nó có thể bỏ lỡ cảnh báo quá tải. Nếu mô hình học mọi spike như tín hiệu thật, nó có thể quá khớp nhiễu. Một cải tiến là thêm nhánh phát hiện spike song song với nhánh dự báo chính.

Ký hiệu biểu diễn ẩn của TimeMixer tại thời điểm t là $\mathbf{h}_t$. Nhánh spike có thể dự báo xác suất xuất hiện spike:

$$p_t = \text{sigmoid}(W_s \mathbf{h}_t + b_s). \quad (49)$$

Nhãn spike có thể được tạo bằng quy tắc thống kê, ví dụ điểm y_t được xem là spike nếu:

$$|y_t - \text{median}(\mathcal{W}_t)| > \alpha \cdot \text{MAD}(\mathcal{W}_t), \quad (50)$$

trong đó $\mathcal{W}_t$ là cửa sổ lân cận và MAD là median absolute deviation. Khi đó, hàm mất mát tổng hợp có thể là:

$$\mathcal{L} = \mathcal{L}_{\text{forecast}} + \beta \mathcal{L}_{\text{spike}}. \quad (51)$$

Nhánh phụ này giúp mô hình học riêng khả năng cảnh báo đỉnh tải mà không phá vỡ nhiệm vụ dự báo trung bình.

5 Tối ưu số quy mô và độ dài lookback

Bài báo TimeMixer cho thấy số quy mô M ảnh hưởng đến hiệu quả dự báo. Với horizon dài, nhiều quy mô hơn có thể giúp mô hình nắm xu hướng tốt hơn. Tuy nhiên, tăng M cũng làm tăng số nhánh xử lý và có thể làm mất quá nhiều chi tiết nếu chuỗi bị hạ lấy mẫu quá mạnh. Vì vậy, cần thực nghiệm với các cặp (L, M) khác nhau.

Một kế hoạch hợp lý là thử:

$$L \in \{96, 192, 336\}, \quad M \in \{1, 2, 3, 4\}. \quad (52)$$

Sau đó đánh giá không chỉ MSE mà còn thời gian huấn luyện, bộ nhớ GPU và độ ổn

định trên tập kiểm tra. Với dữ liệu điện theo giờ, lookback dài hơn có thể giúp mô hình học chu kỳ tuần rõ hơn, nhưng cũng tăng chi phí tính toán.

6 Đánh giá theo từng nhóm kênh

Dữ liệu Electricity có 321 kênh, nhưng không phải mọi kênh đều có cùng hành vi. Một cải tiến trong đánh giá là phân nhóm các kênh theo đặc trưng thống kê như mức tiêu thụ trung bình, biên độ mùa vụ, độ biến động hoặc tần suất spike. Sau đó, mô hình được đánh giá riêng trên từng nhóm. Cách này giúp trả lời câu hỏi TimeMixer mạnh nhất ở loại khách hàng nào và yếu nhất ở loại khách hàng nào.

Ví dụ, có thể tính các đặc trưng:

$$\mu_c = \frac{1}{T} \sum_{t=1}^T x_{t,c}, \quad \sigma_c = \sqrt{\frac{1}{T} \sum_{t=1}^T (x_{t,c} - \mu_c)^2}, \quad (53)$$

rồi dùng phân cụm để chia các kênh thành nhóm tiêu thụ thấp, trung bình, cao hoặc nhóm có dao động mạnh. Việc đánh giá theo nhóm sẽ hữu ích hơn một sai số trung bình toàn cục.

7 Kế hoạch kiểm chứng các cải tiến

Các cải tiến đề xuất có thể được kiểm chứng theo lộ trình sau:

1. Xây dựng lại pipeline chuẩn cho TimeMixer trên Electricity để có kết quả gốc ổn định.
2. Thêm biến ngoại sinh lịch như hour-of-day, day-of-week, weekend/holiday và so sánh với mô hình gốc.
3. Thử Huber Loss và Quantile Loss, đánh giá MSE/MAE đồng thời đánh giá độ phủ khoảng dự báo.
4. Thêm nhánh spike detection và đo precision, recall, F1 đối với các điểm cực trị.
5. Phân tích sai số theo nhóm kênh để xác định nhóm dữ liệu mô hình còn yếu.

8 Kết luận chương

TimeMixer đã có nền tảng kiến trúc mạnh, nhưng vẫn có thể cải thiện khi đưa vào bối cảnh thực tế. Ba hướng quan trọng nhất là tích hợp biến ngoại sinh, chuyển từ dự báo điểm sang dự báo bất định và xử lý spike một cách có chủ đích. Những cải tiến này không thay đổi tinh thần chính của TimeMixer, mà mở rộng mô hình để phù hợp hơn với vận hành lưới điện và các hệ thống ra quyết định thực tế.

VIII KẾT LUẬN

1 Tổng kết nội dung nghiên cứu

Báo cáo đã trình bày một nghiên cứu chi tiết về mô hình TimeMixer cho bài toán dự báo chuỗi thời gian đa biến trên dữ liệu Electricity. Trên cơ sở bài báo *TimeMixer: Decomposable Multiscale Mixing for Time Series Forecasting* [1], báo cáo đã hệ thống hóa lại động lực nghiên cứu, cơ sở lý thuyết, kiến trúc mô hình, thiết lập thực nghiệm, kết quả định lượng và phân tích trực quan.

Trọng tâm của báo cáo là làm rõ vì sao TimeMixer phù hợp với chuỗi thời gian có biến động đa quy mô. Mô hình không xử lý chuỗi như một tín hiệu đơn tầng, mà tạo nhiều biểu diễn ở các quy mô khác nhau. Sau đó, TimeMixer phân rã mỗi quy mô thành mùa vụ và xu hướng, trộn mùa vụ theo hướng bottom-up và trộn xu hướng theo hướng top-down. Cuối cùng, FMM tổng hợp các dự báo từ nhiều quy mô để tạo dự báo cuối cùng. Đây là điểm khác biệt quan trọng giúp TimeMixer vừa giữ được dao động chi tiết, vừa duy trì được xu hướng dài hạn.

2 Kết luận về mặt lý thuyết

Về mặt lý thuyết, TimeMixer cho thấy một hướng tiếp cận đáng chú ý trong dự báo chuỗi thời gian hiện đại. Mô hình không dựa vào attention toàn cục như nhiều kiến trúc Transformer, mà sử dụng MLP trong một cấu trúc đa quy mô có định hướng. Điều này chứng minh rằng hiệu quả của mô hình không chỉ phụ thuộc vào độ phức tạp của khối tính toán, mà còn phụ thuộc vào cách tổ chức luồng thông tin theo bản chất của dữ liệu.

PDM là thành phần thể hiện rõ nhất sự kết hợp giữa tri thức chuỗi thời gian cổ điển và học sâu hiện đại. Việc phân rã trend-seasonality bắt nguồn từ phân tích chuỗi thời gian truyền thống, trong khi việc học biểu diễn và trộn thông tin được thực hiện bằng các lớp MLP. FMM bổ sung một góc nhìn ensemble, trong đó mỗi quy mô đóng góp một khả năng dự báo riêng. Nhờ vậy, TimeMixer có mức độ diễn giải kiến trúc tốt hơn nhiều mô hình hộp đen thuần túy.

3 Kết luận về mặt thực nghiệm

Trên dữ liệu Electricity với $lookback = 96$, TimeMixer đạt sai số thấp nhất ở tất cả các horizon được xét. MSE của TimeMixer lần lượt là 0.1526, 0.1656, 0.1854 và 0.2236 tại các tầm dự báo 96, 192, 336 và 720. Các giá trị này thấp hơn rõ rệt so với Seasonal Naive và XGBoost. Đặc biệt, TimeMixer giảm MSE hơn 38% so với Seasonal Naive và hơn 80% so với XGBoost ở nhiều horizon.

Phần trực quan hóa trên toàn bộ tập kiểm tra củng cố kết quả định lượng. TimeMixer tạo đường dự báo bám mức nền và giữ nhịp mùa vụ tốt. Seasonal Naive là baseline mạnh vì dữ liệu có mùa vụ rõ, nhưng thiếu khả năng thích ứng khi mức nền thay đổi. XGBoost thể hiện hạn chế trong việc tái tạo dao động tuần hoàn mượt và thường kéo dự báo về mức trung bình. Những quan sát này giúp giải thích vì sao TimeMixer đạt kết quả tốt hơn.

4 Ý nghĩa ứng dụng

Trong dự báo phụ tải điện, một mô hình tốt cần chính xác, ổn định và có thể mở rộng cho nhiều kênh. TimeMixer có tiềm năng đáp ứng các yêu cầu này. Cơ chế đa quy mô phù hợp với bản chất phụ tải điện, nơi biến động theo giờ, ngày, tuần và xu hướng dài hạn cùng tồn tại. Kiến trúc thuần MLP giúp giảm chi phí so với một số mô hình attention toàn cục. Ngoài ra, cấu trúc PDM-FMM cho phép giải thích dự báo ở mức mô-đun, giúp người dùng hiểu mô hình dựa vào mùa vụ hay xu hướng.

Tuy nhiên, khi triển khai thực tế, cần bổ sung thêm đánh giá về độ bền vững trước thay đổi phân phối, dữ liệu thiếu, nhiễu cảm biến và các sự kiện bất thường. Ngoài ra, dự báo điểm nên được mở rộng sang dự báo xác suất để hỗ trợ ra quyết định

dưới bất định.

5 Hướng phát triển tiếp theo

Các hướng phát triển chính gồm:

- Tích hợp biến ngoại sinh như nhiệt độ, độ ẩm, ngày lễ và lịch sản xuất để mô hình phản ứng tốt hơn với các điểm uốn do bối cảnh.
- Thử các hàm mất mát bền vững hơn như Huber Loss hoặc các hàm mất mát phân vị để giảm ảnh hưởng của outlier và tạo khoảng dự báo.
- Thêm nhánh phát hiện spike để phục vụ mục tiêu cảnh báo đỉnh tải, thay vì chỉ tối ưu sai số trung bình.
- Đánh giá sai số theo từng nhóm kênh để hiểu rõ mô hình mạnh/yếu ở loại khách hàng nào.
- Mở rộng thí nghiệm sang nhiều bộ dữ liệu khác để kiểm tra tính tổng quát của kết luận.

6 Lời kết

Thông qua việc đọc paper, hệ thống hóa lý thuyết và phân tích thực nghiệm, báo cáo cho thấy TimeMixer là một mô hình có giá trị cả về học thuật lẫn ứng dụng. Mô hình minh họa rõ cách kết hợp tri thức chuỗi thời gian truyền thống với kiến trúc học sâu hiện đại: phân rã để hiểu cấu trúc, đa quy mô để nhìn tín hiệu ở nhiều độ phân giải, và mixing để tổng hợp thông tin hiệu quả. Với các cải tiến phù hợp, TimeMixer có thể trở thành một hướng tiếp cận mạnh cho dự báo phụ tải điện và nhiều bài toán chuỗi thời gian đa biến khác.

Tài liệu tham khảo

- [1] Wang, S., Wu, H., Shi, X., Hu, T., Luo, H., Ma, L., Zhang, J. Y., & Zhou, J. (2024). *TimeMixer: Decomposable Multiscale Mixing for Time Series Forecasting*. International Conference on Learning Representations (ICLR).
- [2] Chen, T., & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.
- [3] Tolstikhin, I. O., Houlsby, N., Kolesnikov, L., Beyer, L., Zhai, X., Unterthiner, T., et al. (2021). *MLP-Mixer: An all-MLP Architecture for Vision*. Advances in Neural Information Processing Systems, 34, 24261–24272.
- [4] Zeng, A., Chen, M., Zhang, L., & Xu, Q. (2023). *Are Transformers Effective for Time Series Forecasting?*. Proceedings of the AAAI Conference on Artificial Intelligence, 37(9), 11121–11128.
- [5] Nie, Y., Nguyen, N. H., Sinthong, P., & Kalagnanam, J. (2023). *A Time Series is Worth 64 Words: Long-term Forecasting with Transformers*. International Conference on Learning Representations (ICLR).
- [6] Wu, H., Xu, J., Wang, J., & Long, M. (2021). *Autoformer: Decomposition Transformers with Auto-Correlation for Long-Term Series Forecasting*. Advances in Neural Information Processing Systems, 34, 22419–22430.
- [7] Zhou, T., Ma, Z., Wen, Q., Wang, X., Sun, L., & Jin, R. (2022). *FEDformer: Frequency Enhanced Decomposed Transformer for Long-term Series Forecasting*. International Conference on Machine Learning (ICML).
- [8] Zhou, H., Zhang, S., Peng, J., Zhang, S., Li, J., Xiong, H., & Zhang, W. (2021). *Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting*. Proceedings of the AAAI Conference on Artificial Intelligence.

- [9] Wu, H., Hu, T., Liu, Y., Zhou, H., Wang, J., & Long, M. (2023). *TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis*. International Conference on Learning Representations (ICLR).
- [10] Kingma, D. P., & Ba, J. (2015). *Adam: A Method for Stochastic Optimization*. International Conference on Learning Representations (ICLR).
- [11] Cleveland, R. B., Cleveland, W. S., McRae, J. E., & Terpenning, I. (1990). *STL: A Seasonal-Trend Decomposition Procedure Based on Loess*. Journal of Official Statistics.
- [12] Huber, P. J. (1964). *Robust Estimation of a Location Parameter*. Annals of Mathematical Statistics.
- [13] Koenker, R., & Bassett, G. (1978). *Regression Quantiles*. Econometrica.